



پردیس علوم
دانشکده ریاضی، آمار و علوم کامپیوتر

شناسایی فعالیت‌های گروهی برای تحلیل ویدیوهای ورزشی

نگارنده

امید نائیج نژاد

استاد راهنما: دکتر ضیائی تبار

پایان‌نامه برای دریافت درجه کارشناسی
در رشته علوم کامپیوتر

خرداد ۱۴۰۵

چکیده

در سال‌های اخیر، تحلیل خودکار ویدیو و درک فعالیت‌های گروهی به یکی از مسائل مهم در حوزه بینایی ماشین تبدیل شده است. یکی از زیرشاخه‌های این حوزه، تشخیص فعالیت گروهی^۱ است که هدف آن شناسایی رفتار جمعی افراد در یک صحنه بر اساس تعاملات فضایی و زمانی میان آن‌ها می‌باشد. این مسئله به‌ویژه در تحلیل ویدیوهای ورزشی اهمیت بالایی دارد، زیرا درک صحیح فعالیت‌های تیمی می‌تواند کاربردهای گسترده‌ای در تحلیل تاکتیکی، ارزیابی عملکرد و سیستم‌های هوشمند ورزشی داشته باشد.

هدف اصلی این پژوهش، بررسی و ارزیابی رویکردهای مبتنی بر یادگیری عمیق برای تشخیص فعالیت‌های گروهی در ویدیوهای ورزشی است. در این راستا، چندین معماری مختلف شامل مدل‌های مبتنی بر شبکه‌های عصبی کانولوشنی-بازگشتی و همچنین معماری‌های مبتنی بر ترنسفورمر مورد بررسی و پیاده‌سازی قرار گرفته‌اند تا توانایی هر یک در مدل‌سازی وابستگی‌های فضایی و زمانی در داده‌های ویدیویی تحلیل شود.

آزمایش‌ها بر روی مجموعه داده‌ای از ویدیوهای ورزشی انجام شده و عملکرد مدل‌ها با استفاده از معیارهای استاندارد ارزیابی مثل F1-score سنجیده شده است. نتایج به‌دست‌آمده نشان می‌دهد که مدل‌های مبتنی بر ترنسفورمر، به‌ویژه در مدل‌سازی روابط بلندمدت زمانی، عملکرد رقابتی و در برخی موارد برتری نسبت به روش‌های سنتی‌تر دارند. با این حال، محدودیت‌هایی مانند اندازه کوچک داده‌ها و پیچیدگی محاسباتی همچنان تأثیر قابل توجهی بر عملکرد نهایی دارند. در مجموع، این پژوهش ضمن ارائه یک مقایسه جامع میان رویکردهای مختلف، نشان می‌دهد که انتخاب معماری مناسب در مسئله تشخیص فعالیت گروهی باید با توجه به محدودیت داده و منابع محاسباتی انجام شود. این نتایج می‌تواند به عنوان پایه‌ای برای تحقیقات آینده در زمینه تحلیل ویدیوهای ورزشی و توسعه مدل‌های کارآمدتر مورد استفاده قرار گیرد.

¹Group Activity Recognition

سپاسگزاری

از استاد بزرگوارم سرکار خانم دکتر ضیایی تبار که با کمک‌ها و راهنمایی‌های بی‌دریغشان، نقش به‌سزایی در پیشبرد این پروژه ایفا کردند، صمیمانه سپاسگزارم.

پیشگفتار

مسئله تشخیص فعالیت‌های گروهی در ویدیوهای ورزشی یکی از موضوعات مهم و نسبتاً جدید در حوزه بینایی ماشین به شمار می‌رود که هدف آن، درک خودکار رفتار جمعی افراد در یک صحنه ویدئویی است. در این مسئله، برخلاف تحلیل تک‌فردی، سیستم باید بتواند روابط و تعاملات میان چندین فرد را به‌صورت هم‌زمان درک کرده و بر اساس آن، نوع فعالیت کلی گروه را تشخیص دهد. این موضوع به‌طور مستقیم با چالش‌هایی مانند تغییرات سریع حرکتی، هم‌پوشانی افراد، تنوع دید دوربین و پیچیدگی تعاملات انسانی همراه است.

تلاش برای حل این مسئله سابقه‌ای نسبتاً طولانی در حوزه بینایی ماشین دارد. در ابتدا، روش‌های مبتنی بر ویژگی‌های دستی و مدل‌های کلاسیک یادگیری ماشین مورد استفاده قرار می‌گرفتند که معمولاً توانایی محدودی در درک روابط پیچیده زمانی و مکانی داشتند. با پیشرفت یادگیری عمیق، به‌ویژه شبکه‌های کانولوشنی و سپس مدل‌های مبتنی بر توالی و ترنسفورمرها، رویکردهای جدیدی برای استخراج ویژگی‌های فضایی و زمانی معرفی شدند که توانستند عملکرد این حوزه را به‌طور قابل توجهی بهبود دهند. در میان این تلاش‌ها، مدل‌هایی مانند شبکه‌های سه‌بعدی کانولوشنی، شبکه‌های ترکیبی CNN-RNN و معماری‌های ترنسفورمری، نقش مهمی در توسعه روش‌های نوین تشخیص فعالیت گروهی ایفا کرده‌اند. از جمله کارهای مهم در این حوزه می‌توان به پژوهش‌های انجام‌شده بر روی مدل‌های ویدئویی مبتنی بر ترنسفورمر مانند TimeSformer و همچنین مدل‌های مبتنی بر توکن‌سازی ویدئو مانند ViT اشاره کرد که مسیر جدیدی را در تحلیل داده‌های ویدئویی باز کرده‌اند.

اهمیت این پژوهش در آن است که تشخیص دقیق فعالیت‌های گروهی، کاربردهای گسترده‌ای در تحلیل مسابقات ورزشی، سیستم‌های نظارت تصویری، تحلیل رفتار جمعی و حتی سیستم‌های هوشمند کمک‌داور دارد. از این رو، بهبود دقت و پایداری مدل‌ها در این حوزه می‌تواند تأثیر مستقیمی بر عملکرد سیستم‌های واقعی داشته باشد.

در این پایان‌نامه، مجموعه‌ای از مدل‌های یادگیری عمیق برای تشخیص فعالیت‌های گروهی مورد بررسی و مقایسه قرار گرفته‌اند. تمرکز اصلی بر تحلیل توانایی مدل‌ها در استخراج ویژگی‌های فضایی و زمانی از ویدیوهای ورزشی بوده است. در این راستا، مدل‌های مبتنی بر شبکه‌های کانولوشنی-بازگشتی و معماری‌های مبتنی بر ترنسفورمر مورد استفاده قرار گرفته‌اند و عملکرد آن‌ها در شرایط یکسان ارزیابی شده است.

ساختار پایان نامه به این صورت است که ابتدا در فصل اول، کلیات مسئله، اهمیت آن و زمینه های کاربردی تشخیص فعالیت گروهی ارائه می شود. در فصل دوم، پیشینه تحقیق و روش های موجود در این حوزه مورد بررسی قرار می گیرد. فصل سوم به معرفی داده ها و روش پیشنهادی اختصاص دارد و در آن فرآیند آماده سازی داده ها و پیاده سازی مدل ها توضیح داده می شود. در فصل چهارم، نتایج تجربی و تحلیل عملکرد مدل ها ارائه می گردد و در نهایت، فصل پنجم شامل جمع بندی نتایج و ارائه پیشنهادهایی برای کارهای آینده خواهد بود.

فهرست مطالب

۱	مقدمه	۱
۱	۱.۱ زمینه و پیشینه مسئله	۱.۱
۲	۲.۱ کاربردها	۲.۱
۲	۱.۲.۱ تحلیل ویدیوهای ورزشی	۱.۲.۱
۲	۲.۲.۱ نظارت و امنیت	۲.۲.۱
۲	۳.۲.۱ حمل و نقل هوشمند	۳.۲.۱
۳	۴.۲.۱ رباتیک و تعامل انسان-ماشین	۴.۲.۱
۳	۵.۲.۱ تحلیل رفتار اجتماعی و سلامت	۵.۲.۱
۳	۳.۱ تعریف مسئله	۳.۱
۴	۴.۱ ابعاد و چالش‌ها	۴.۱
۴	۵.۱ اهمیت مسئله	۵.۱
۵	۶.۱ سهم این پژوهش	۶.۱
۵	۷.۱ ساختار و نقشه راه	۷.۱
۶	مروری بر روش‌های پیشین	۲
۶	۱.۲ مقدمه	۱.۲
۷	۲.۲ تکامل تشخیص فعالیت	۲.۲
۷	۳.۲ روش‌های سنتی (پیش از یادگیری عمیق)	۳.۲
۸	۴.۲ یادگیری عمیق برای تشخیص فعالیت گروهی	۴.۲
۸	۱.۴.۲ مدل‌های CNN-RNN و مدل‌های زمانی سلسله‌مراتبی	۱.۴.۲
۹	۲.۴.۲ مدل‌های تعاملی و مبتنی بر روابط	۲.۴.۲
۹	۳.۴.۲ مدل‌های مبتنی بر ترنسفورمر	۳.۴.۲
۱۰	۴.۴.۲ روش‌های مبتنی بر ژست	۴.۴.۲
۱۰	۵.۲ کاربردها در تحلیل ویدیوهای ورزشی	۵.۲
۱۱	۶.۲ مجموعه داده‌ها و بنچمارک‌ها	۶.۲
۱۲	۷.۲ چالش‌ها و شکاف‌های پژوهشی	۷.۲
۱۲	۸.۲ چشم‌اندازهای آینده	۸.۲
۱۳	۹.۲ جمع‌بندی	۹.۲

۱۵	۳ روش‌شناسی
۱۶	۱.۳ توصیف مجموعه داده و چالش‌های مرتبط
۱۹	۲.۳ مدل‌های مورد بررسی
۱۹	۱.۲.۳ نوع یک: مدل‌های ترکیبی کانولوشنی-توالی محور
۱۹	مدل ۱: رمزگذار کانولوشنی + شبکه عصبی بازگشتی
۱۹	مدل ۲: رمزگذار کانولوشنی + شبکه LSTM
۲۰	مدل ۳: رمزگذار کانولوشنی + شبکه LSTM دوطرفه
۲۰	۲.۲.۳ نوع دو: مدل مبتنی بر ترنسفورمر فضایی-زمانی
۲۱	مراحل آماده‌سازی داده‌ها
۲۱	معماری مدل
۲۲	راهبرد آموزش مدل
۲۲	فرآیند کلی اجرای مدل
۲۳	مزایا و محدودیت‌های مدل
۲۴	۳.۳ صورت‌بندی مسئله
۲۵	۴ ارزیابی و تحلیل نتایج
۲۵	۱.۴ تحلیل آماری مجموعه داده
۲۸	۲.۴ معیارهای ارزیابی
۲۸	۱.۲.۴ دقت کلی
۲۸	۲.۲.۴ دقت به ازای هر کلاس
۲۸	۳.۲.۴ صحت
۲۹	۴.۲.۴ بازخوانی
۲۹	۵.۲.۴ میانگین F۱ ماکرو
۳۰	۶.۲.۴ میانگین F۱ وزنی
۳۱	۳.۴ مقایسه عملکرد مدل‌ها
۳۱	۱.۳.۴ مدل ۱: رمزگذار کانولوشنی + شبکه عصبی بازگشتی
۳۳	۲.۳.۴ مدل ۲: رمزگذار کانولوشنی + LSTM
۳۵	۳.۳.۴ مدل ۳: رمزگذار کانولوشنی + Bi-LSTM
۳۷	۴.۳.۴ مدل ۴: مدل مبتنی بر ترنسفورمر فضایی-زمانی
۴۰	۵ نتیجه‌گیری و چشم‌انداز آینده
۴۰	۱.۵ نتیجه‌گیری
۴۳	۲.۵ کارهای آینده
۴۵	واژه‌نامه فارسی به انگلیسی
۴۹	واژه‌نامه انگلیسی به فارسی

فهرست جداول

۱.۲	خلاصه‌ای از رویکردهای بررسی شده تشخیص فعالیت‌های گروهی	۱۴
۱.۴	نتایج کلی مدل CNN+RNN	۳۱
۲.۴	عملکرد مدل CNN+RNN به‌ازای هر کلاس	۳۱
۳.۴	نتایج کلی مدل CNN+LSTM	۳۳
۴.۴	عملکرد مدل CNN+LSTM به‌ازای هر کلاس	۳۳
۵.۴	نتایج کلی مدل CNN+Bi-LSTM	۳۵
۶.۴	عملکرد مدل CNN+Bi-LSTM به‌ازای هر کلاس	۳۵
۷.۴	نتایج کلی مدل TimeSformer	۳۷
۸.۴	عملکرد مدل TimeSformer به‌ازای هر کلاس	۳۷
۱.۵	تحلیل ساختاری و مقایسه‌ای معماری‌های تشخیص فعالیت گروهی	۴۱

فهرست تصاویر

۱۵	نمای کلی خط لوله‌ی دسته‌بندی کنش‌های گروهی	۱.۳
۱۷	مراحل اصلی در ساخت مجموعه‌داده برای تحلیل کنش‌های گروهی	۲.۳
۱۸	نمونه‌هایی از داده‌های مصنوعی تولید شده توسط چارچوب M3Act	۳.۳
۲۱	معماری ویژن ترنسفورمر	۴.۳
۲۳	مراحل اصلی مدل مبتنی بر ترنسفورمر فضایی-زمانی	۵.۳
۲۶	نمودار میله‌ای توزیع کلاس‌های دیتاست کنش‌های فوتبالی	۱.۴
۲۷	چند نمونه از دیتاست کنش‌های فوتبالی	۲.۴
۳۲	ماتریس درهم‌ریختگی عملکرد مدل CNN+RNN روی داده‌های آزمایش	۳.۴
۳۴	ماتریس درهم‌ریختگی عملکرد مدل CNN+LSTM روی داده‌های آزمایش	۴.۴
۳۶	ماتریس درهم‌ریختگی عملکرد مدل CNN+Bi-LSTM روی داده‌های آزمایش	۵.۴
۳۸	ماتریس درهم‌ریختگی عملکرد مدل TimeSformer روی داده‌های آزمایش	۶.۴

فصل ۱

مقدمه

۱.۱ زمینه و پیشینه مسئله

تشخیص فعالیت‌های گروهی^۱ یکی از مسائل بنیادین در حوزه بینایی ماشین^۲ است که هدف آن درک رفتار جمعی افراد در یک صحنه ویدئویی می‌باشد. برخلاف تشخیص کنش‌های فردی که تنها بر حرکات یک شخص تمرکز دارد، در GAR تعاملات میان چندین عامل (انسان‌ها) و همچنین ارتباط آن‌ها با زمینه محیطی اهمیت اساسی پیدا می‌کند. از دیدگاه تاریخی و فلسفی، مسئله درک فعالیت‌های گروهی ریشه در تلاش برای پاسخ به این پرسش دارد که «چگونه می‌توان از رفتارهای فردی به درک رفتار جمعی رسید؟». در رویکردهای اولیه بینایی ماشین، تمرکز عمدتاً بر استخراج ویژگی‌های سطح پایین نظیر حرکت، لبه‌ها و مسیرهای حرکتی بود. این رویکردها بر این فرض استوار بودند که با ترکیب ویژگی‌های فردی می‌توان به یک نمایش مناسب از رفتار گروهی دست یافت. با این حال، این دیدگاه اغلب از مدل‌سازی تعاملات پیچیده و وابستگی‌های زمانی-مکانی بین افراد ناتوان بود. با پیشرفت روش‌های یادگیری ماشین^۳، به‌ویژه مدل‌های احتمالاتی مانند HMM^۴ و CRF^۵، تلاش شد تا وابستگی‌های زمانی بهتر مدل‌سازی شوند. اما نقطه عطف اصلی در این حوزه با ظهور یادگیری عمیق^۶ رقم خورد. شبکه‌های عصبی کانولوشنی^۷ امکان استخراج خودکار ویژگی‌های

^۱Group Activity Recognition (GAR)

^۲Machine Vision

^۳Machine Learning

^۴Hidden Markov Models (HMMs)

^۵Conditional Random Fields (CRFs)

^۶Deep Learning

^۷Convolutional Neural Networks (CNNs)

فضایی را فراهم کردند و مدل‌های بازگشتی^۸ و بعدتر ترنسفورمرها^۹، وابستگی‌های زمانی و تعاملات پیچیده‌تر را پوشش دادند. در سال‌های اخیر، استفاده از گراف‌ها و مکانیزم‌های توجه^{۱۰} برای مدل‌سازی روابط بین افراد، به یکی از جریان‌های اصلی پژوهشی در تشخیص فعالیت‌های گروهی تبدیل شده است. به‌طور کلی، تحول تشخیص فعالیت‌های گروهی را می‌توان به گذار از «ویژگی‌های دست‌ساخته^{۱۱}» به «یادگیری نمایش» و سپس به «مدل‌سازی تعاملات پیچیده» تعبیر کرد؛ گذاری که نشان‌دهنده حرکت این حوزه به سمت درک معنایی عمیق‌تر از صحنه‌های اجتماعی است.

۲.۱ کاربردها

۱.۲.۱ تحلیل ویدیوهای ورزشی

یکی از مهم‌ترین حوزه‌های کاربردی تشخیص فعالیت‌های گروهی، تحلیل ویدیوهای ورزشی است. در ورزش‌هایی مانند فوتبال، بسکتبال و والیبال، بسیاری از رویدادهای کلیدی ماهیتی گروهی دارند و تنها با در نظر گرفتن تعاملات میان بازیکنان قابل درک هستند. به‌عنوان مثال، تشخیص موقعیت‌های گل، آرایش‌های تیمی، الگوهای پاس‌کاری و یا رفتارهای دفاعی، نیازمند تحلیل هم‌زمان چندین بازیکن و روابط میان آن‌ها است. استفاده از GAR در این حوزه می‌تواند به تحلیل تاکتیکی تیم‌ها، بهبود تصمیم‌گیری مربیان، داوری خودکار و تولید خلاصه‌های هوشمند از مسابقات منجر شود.

۲.۲.۱ نظارت و امنیت

در سیستم‌های نظارتی، درک رفتارهای گروهی نقش مهمی در شناسایی موقعیت‌های غیرعادی دارد. فعالیت‌هایی مانند درگیری، تجمع‌های غیرمعمول یا رفتارهای تهدیدآمیز اغلب به‌صورت گروهی رخ می‌دهند و تشخیص آن‌ها نیازمند تحلیل تعاملات میان افراد است. GAR می‌تواند به‌عنوان یک ابزار کلیدی در افزایش امنیت محیط‌های عمومی مانند فرودگاه‌ها، ایستگاه‌های مترو، قطار و فضاهای شهری مورد استفاده قرار گیرد.

۳.۲.۱ حمل‌ونقل هوشمند

در حوزه حمل‌ونقل، تحلیل رفتار جمعی عابران پیاده و وسایل نقلیه اهمیت زیادی دارد. درک نحوه حرکت گروهی افراد در تقاطع‌ها یا رفتار جمعی خودروها در شرایط مختلف ترافیکی می‌تواند

^۸Recurrent Neural Networks (RNNs)

^۹Transformers

^{۱۰}Attention Mechanisms

^{۱۱}Handcrafted Features

به طراحی سیستم‌های هوشمندتر برای مدیریت ترافیک و افزایش ایمنی کمک کند. در این زمینه، GAR می‌تواند نقش مهمی در پیش‌بینی رفتارهای جمعی و جلوگیری از حوادث ایفا کند.

۴.۲.۱ رباتیک و تعامل انسان-ماشین^{۱۲}

در محیط‌های اجتماعی، ربات‌ها برای تعامل مؤثر با انسان‌ها نیازمند درک رفتارهای گروهی هستند. به عنوان مثال، یک ربات خدماتی باید بتواند رفتار یک گروه از افراد را تحلیل کرده و تصمیم‌گیری مناسبی انجام دهد. این مسئله به‌ویژه در محیط‌های شلوغ مانند مراکز خرید یا فرودگاه‌ها اهمیت پیدا می‌کند.

۵.۲.۱ تحلیل رفتار اجتماعی و سلامت

درک رفتارهای گروهی می‌تواند در تحلیل الگوهای اجتماعی و حتی مسائل مرتبط با سلامت روان مورد استفاده قرار گیرد. بررسی نحوه تعامل افراد در محیط‌های اجتماعی می‌تواند به شناسایی الگوهای رفتاری خاص و حتی نشانه‌های اختلالات اجتماعی کمک کند. این کاربرد نشان‌دهنده اهمیت GAR فراتر از حوزه‌های فنی و در ارتباط با علوم انسانی است.

۳.۱ تعریف مسئله

مسئله تشخیص فعالیت‌های گروهی را می‌توان به صورت رسمی^{۱۳} به عنوان نگاشت^{۱۴} یک دنباله ویدئویی به یک یا چند برجسب فعالیت تعریف کرد. فرض کنید یک ویدئو به صورت دنباله‌ای از فریم‌ها نمایش داده شود:

$$V = \{I_1, I_2, \dots, I_T\}$$

که در آن T تعداد فریم‌ها است. در هر فریم، مجموعه‌ای از افراد حضور دارند که می‌توان آن‌ها را به صورت زیر نمایش داد:

$$P_t = \{p_1, p_2, \dots, p_{N_t}\}$$

در اینجا N_t تعداد افراد در فریم t است. هدف، یادگیری تابعی است که بتواند این دنباله ویدئویی را به یک برجسب فعالیت گروهی نگاشت کند:

$$f : V \rightarrow Y$$

¹²Human-Machine Interaction

¹³Formal

¹⁴Mapping

که در آن Y نشان دهنده کلاس فعالیت گروهی است. در تنظیمات پیچیده تر، این نگاشت می تواند به صورت تابعی از دنباله ای از برچسب ها در طول زمان یا حتی ترکیبی از برچسب های فردی و گروهی تعریف شود. این تعریف نشان می دهد که مسئله تشخیص فعالیت های گروهی، ذاتاً یک مسئله چندسطحی است که شامل تحلیل هم زمان اطلاعات فضایی، زمانی و رابطه ای می باشد.

۴.۱ ابعاد و چالش ها

یکی از مهم ترین ابعاد مسئله تشخیص فعالیت های گروهی، نیاز به مدل سازی تعاملات میان افراد است. رفتار گروهی تنها از طریق تحلیل مستقل هر فرد قابل درک نیست، بلکه روابط میان افراد نقش تعیین کننده ای دارند. این موضوع باعث می شود که مدل سازی وابستگی های بین فردی به یکی از چالش های اصلی تبدیل شود.

علاوه بر این، فعالیت های گروهی معمولاً در طول زمان شکل می گیرند و وابستگی های زمانی نقش مهمی در تعریف آن ها دارند. بنابراین، مدل باید قادر به درک پویایی های زمانی و ارتباط میان فریم های مختلف باشد. این مسئله به ویژه در سناریوهایی که فعالیت ها دارای ساختار زمانی پیچیده هستند، اهمیت بیشتری پیدا می کند.

تنوع در شرایط تصویربرداری نیز یکی دیگر از چالش های مهم است. تغییر در زاویه دید، نور، پس زمینه و تعداد افراد حاضر در صحنه می تواند باعث کاهش دقت مدل شود. همچنین، در بسیاری از مجموعه داده ها، توزیع کلاس ها نامتوازن است که این موضوع فرآیند یادگیری را با دشواری مواجه می کند.

در نهایت، افزایش تعداد افراد در صحنه منجر به رشد نمایی پیچیدگی در مدل سازی تعاملات می شود. این مسئله نیازمند طراحی مدل هایی است که بتوانند به صورت کارآمد و مقیاس پذیر این روابط را مدیریت کنند.

۵.۱ اهمیت مسئله

اهمیت تشخیص فعالیت های گروهی را می توان از چندین منظر مورد بررسی قرار داد. از منظر علمی، این مسئله در تقاطع بینایی ماشین، یادگیری ماشین و علوم شناختی قرار دارد و به درک بهتر رفتارهای اجتماعی کمک می کند. از منظر کاربردی، گسترده گی کاربردهای آن در حوزه هایی مانند ورزش، امنیت، حمل و نقل و سلامت، نشان دهنده نقش حیاتی آن در سیستم های هوشمند مدرن است.

از منظر فنی نیز، GAR یکی از مسائل چالش برانگیز محسوب می شود که نیازمند ترکیب روش های پیشرفته در مدل سازی فضایی، زمانی و رابطه ای است. حل این مسئله می تواند به پیشرفت در سایر حوزه های مرتبط نیز منجر شود.

۶.۱ سهم این پژوهش

در این پایان‌نامه، تمرکز اصلی بر تشخیص فعالیت‌های گروهی در ویدیوهای ورزشی است. در این راستا، یک چارچوب مبتنی بر یادگیری عمیق برای تحلیل این نوع فعالیت‌ها ارائه می‌شود که قادر است ویژگی‌های فضایی و زمانی را به‌صورت مؤثر استخراج و ترکیب کند. همچنین، تلاش شده است تا با بررسی و مقایسه رویکردهای موجود، نقاط قوت و ضعف آن‌ها تحلیل شده و در طراحی مدل پیشنهادی مورد توجه قرار گیرد.

مدل ارائه‌شده در این تحقیق به‌گونه‌ای طراحی شده است که بتواند تعاملات میان افراد را به‌صورت کارآمد مدل‌سازی کند و در عین حال با چالش‌هایی مانند عدم توازن داده‌ها مقابله نماید. ارزیابی این مدل بر روی یک مجموعه داده واقعی انجام شده و نتایج حاصل، کارایی آن را در مقایسه با روش‌های موجود نشان می‌دهد.

۷.۱ ساختار و نقشه راه

این پایان‌نامه در پنج فصل سازمان‌دهی شده است. در فصل دوم، مروری جامع بر ادبیات موضوع ارائه شده و رویکردهای مختلف در تشخیص فعالیت‌های گروهی مورد بررسی قرار می‌گیرند. فصل سوم به معرفی روش پیشنهادی اختصاص دارد و شامل تعریف دقیق مسئله، معماری مدل و جزئیات پیاده‌سازی است. در فصل چهارم، نتایج آزمایش‌ها و ارزیابی عملکرد مدل ارائه و تحلیل می‌شود. در نهایت، فصل پنجم به جمع‌بندی مطالب، نتیجه‌گیری و ارائه پیشنهاداتی برای پژوهش‌های آینده اختصاص دارد.

فصل ۲

مروری بر روش‌های پیشین

۱.۲ مقدمه

تشخیص فعالیت گروهی یکی از زیرشاخه‌های بینایی کامپیوتر^۱ است که بر شناسایی رفتارهای جمعی انجام شده توسط چندین فرد در توالی‌های ویدیویی^۲ تمرکز دارد. برخلاف تشخیص کنش تک نفره^۳ که به دسته‌بندی اعمال مجزا می‌پردازد، در این حوزه لازم است روابط و تعاملات فضایی-زمانی^۴ میان چندین بازیگر مدل‌سازی شود تا بتوان یک فعالیت گروهی واحد را استنتاج کرد [۱، ۲]. این تفاوت بنیادی موجب شده است که تشخیص فعالیت گروهی به مسئله‌ای پیچیده‌تر و چندلایه‌تر نسبت به تشخیص کنش فردی تبدیل شود.

اهمیت این مسئله به‌ویژه در تحلیل ویدیوهای ورزشی^۵ برجسته می‌شود، جایی که درک رفتارهای هماهنگ تیمی^۶—مانند حملات سازمان‌یافته در بسکتبال، آرایش‌های دفاعی در فوتبال، یا استراتژی‌های تهاجمی در والیبال—نقش کلیدی در استخراج بینش‌های تاکتیکی و ارزیابی عملکرد دارد [۳، ۴]. در چنین سناریوهایی، تحلیل صرف رفتار فردی کافی نیست و لازم است تعاملات میان بازیکنان و ساختار کلی تیم نیز مورد توجه قرار گیرد.

با این حال، پیچیدگی‌های ذاتی این مسئله، از جمله انسداد^۷، تعاملات پویا میان بازیکنان، و نیاز به یکپارچه‌سازی اطلاعات در سطوح مختلف، چالش‌های قابل توجهی را ایجاد می‌کند. این عوامل باعث می‌شوند که مدل‌سازی دقیق روابط میان افراد و درک زمینه کلی صحنه از اهمیت ویژه‌ای برخوردار باشد [۳، ۵]. در این فصل، سیر تکامل روش‌های تشخیص فعالیت گروهی از

¹Computer Vision

²Video Sequence

³Single-person Action Recognition

⁴Spatio-temporal Relationships

⁵Sports Video Analysis

⁶Team Behavior

⁷Occlusion

رویکردهای اولیه مبتنی بر ویژگی‌های دست‌ساخته تا تکنیک‌های مدرن یادگیری عمیق بررسی شده و تمرکز ویژه‌ای بر کاربردهای ورزشی این حوزه خواهد بود.

۲.۲ تکامل تشخیص فعالیت

پژوهش در حوزه تشخیص فعالیت به‌صورت تدریجی و همگام با افزایش پیچیدگی سناریوهای مورد بررسی تکامل یافته است. در مراحل اولیه، تمرکز عمدتاً بر تشخیص کنش تک‌نفره^۸ بود، که هدف آن شناسایی اعمالی مانند دویدن یا پریدن در سطح فردی است [۶]. این رویکردها اگرچه در محیط‌های ساده عملکرد مناسبی داشتند، اما در مواجهه با تعاملات انسانی محدودیت‌هایی از خود نشان دادند.

در گام بعدی، توجه پژوهشگران به سمت تشخیص تعامل دونفره^۹ معطوف شد، جایی که هدف مدل‌سازی روابط میان جفتی از افراد بود [۷]. این سطح از تحلیل امکان درک ابتدایی از تعاملات انسانی را فراهم کرد، اما همچنان برای سناریوهای پیچیده‌تر کافی نبود.

در نهایت، تشخیص فعالیت گروهی به‌عنوان سطحی پیشرفته‌تر معرفی شد که در آن رفتارهای هماهنگ میان چندین فرد به‌صورت همزمان مورد تحلیل قرار می‌گیرد [۳]. این سطح از پیچیدگی مستلزم درک همزمان کنش‌های فردی و نحوه ارتباط آن‌ها در یک زمینه مشترک است. در کاربردهای ورزشی، این موضوع به معنای تحلیل ساختارهای تیمی، هماهنگی میان بازیکنان و تغییرات دینامیک در طول زمان است [۳، ۵].

۳.۲ روش‌های سنتی (پیش از یادگیری عمیق)

پیش از ظهور یادگیری عمیق، رویکردهای تشخیص فعالیت گروهی عمدتاً بر ویژگی‌های دست‌ساخته و مدل‌های احتمالاتی ساخت‌یافته^{۱۰} متکی بودند [۸، ۹]. این روش‌ها تلاش می‌کردند با طراحی ویژگی‌های مناسب و استفاده از مدل‌های آماری، رفتارهای گروهی را توصیف کنند. در این چارچوب، ویژگی‌های فضایی-زمانی به‌صورت دستی استخراج می‌شدند. برای مثال، جریان نوری و مسیرهای حرکتی^{۱۱} به‌منظور توصیف حرکت، توصیف‌گرهای ظاهری^{۱۲} برای نمایش ویژگی‌های بصری، و روابط فضایی میان افراد^{۱۳} برای درک ساختار صحنه مورد استفاده قرار می‌گرفتند. این ویژگی‌ها اگرچه قادر به ثبت برخی الگوهای حرکتی بودند، اما به دلیل ماهیت دستی خود، محدودیت‌هایی در پوشش تمامی جنبه‌های تعاملات پیچیده داشتند [۸].

^۸Single-person Action Recognition

^۹Two-person Interaction Recognition

^{۱۰}structured probabilistic models

^{۱۱}Optical Flow and Motion Trajectories

^{۱۲}Appearance Descriptors

^{۱۳}Spatial Relationships Between Individuals

برای مدل‌سازی پویایی‌های زمانی و وابستگی‌های میان افراد، از مدل‌های آماری ساخت‌یافته‌ای مانند مدل‌های مارکوف پنهان^{۱۴}، میدان‌های تصادفی شرطی^{۱۵} و میدان‌های تصادفی سلسله‌مراتبی^{۱۶} استفاده می‌شد. این مدل‌ها تلاش می‌کردند وابستگی میان کنش‌های فردی و فعالیت‌های گروهی را به‌صورت صریح نمایش دهند [۹، ۱۰].

با وجود این تلاش‌ها، روش‌های سنتی با محدودیت‌های جدی مواجه بودند. وابستگی به ویژگی‌های دست‌ساخته باعث کاهش توان بازنمایی این مدل‌ها می‌شد و در نتیجه، عملکرد آن‌ها در صحنه‌های پیچیده با تعداد زیاد افراد کاهش می‌یافت. علاوه بر این، این روش‌ها در مدل‌سازی تعاملات پویا، به‌ویژه در محیط‌هایی مانند ورزش‌های تیمی، کارایی محدودی داشتند. این چالش‌ها در نهایت زمینه‌ساز حرکت به سمت رویکردهای مبتنی بر داده و یادگیری عمیق شدند [۳، ۴].

۴.۲ یادگیری عمیق برای تشخیص فعالیت گروهی

ورود یادگیری عمیق نقطه عطفی اساسی در توسعه روش‌های تشخیص فعالیت گروهی محسوب می‌شود، زیرا این رویکرد امکان یادگیری خودکار بازنمایی‌های پیچیده و سلسله‌مراتبی را مستقیماً از داده فراهم می‌کند [۳، ۱۱]. برخلاف روش‌های سنتی که وابسته به طراحی دستی ویژگی‌ها بودند، مدل‌های یادگیری عمیق قادرند الگوهای پنهان در داده‌های بصری و زمانی را به‌صورت یکپارچه استخراج کنند. این ویژگی به‌ویژه در سناریوهای پیچیده مانند تحلیل ویدیوهای ورزشی، که شامل تعاملات چندگانه و تغییرات سریع صحنه است، اهمیت زیادی دارد.

۱.۴.۲ مدل‌های CNN-RNN و مدل‌های زمانی سلسله‌مراتبی

در نخستین نسل از روش‌های مبتنی بر یادگیری عمیق، تلاش شد تا ویژگی‌های فضایی و زمانی به‌صورت مجزا اما مکمل مدل‌سازی شوند. در این چارچوب، شبکه‌های عصبی کانولوشنی برای استخراج ویژگی‌های فضایی از فریم‌های ویدیویی به‌کار گرفته شدند، در حالی که شبکه‌های عصبی بازگشتی^{۱۷}، به‌ویژه معماری‌های LSTM، برای مدل‌سازی وابستگی‌های زمانی میان این ویژگی‌ها مورد استفاده قرار گرفتند. این ترکیب امکان تحلیل توالی‌های ویدیویی را فراهم کرد و گامی مهم در جهت مدل‌سازی رفتارهای پویا به‌شمار می‌رفت.

یکی از نمونه‌های برجسته در این حوزه، مدل زمانی عمیق سلسله‌مراتبی^{۱۸} است که ساختاری دو سطحی برای تحلیل فعالیت‌ها ارائه می‌دهد. در این مدل، ابتدا کنش‌های فردی توسط یک LSTM در سطح پایین مدل‌سازی شده و سپس خروجی این مرحله به یک LSTM سطح بالاتر منتقل می‌شود تا بازنمایی کلی از فعالیت گروهی ایجاد گردد. این طراحی سلسله‌مراتبی به‌خوبی

¹⁴Hidden Markov Models (HMMs)

¹⁵Conditional Random Fields (CRFs)

¹⁶Hierarchical Random Fields

¹⁷Recurrent Neural Networks (RNNs)

¹⁸Hierarchical Deep Temporal Model (HDTM)

بازتاب‌دهنده ماهیت چندسطحی رفتارهای گروهی است، جایی که فعالیت کلی از تعامل و ترکیب کنش‌های فردی شکل می‌گیرد [۳]. با وجود این مزایا، این دسته از مدل‌ها تعاملات میان افراد را به صورت صریح در نظر نمی‌گیرند و عمدتاً بر تجمیع اطلاعات فردی تکیه دارند. در نتیجه، در سناریوهایی که روابط میان بازیگران نقش تعیین‌کننده‌ای دارند، عملکرد آن‌ها محدود می‌شود.

۲.۴.۲ مدل‌های تعاملی و مبتنی بر روابط^{۱۹}

به منظور رفع محدودیت‌های مدل‌های اولیه، پژوهش‌ها به سمت توسعه روش‌هایی حرکت کردند که بتوانند تعاملات میان افراد را به صورت صریح مدل‌سازی کنند. در این راستا، نمایش‌های گرافی به عنوان ابزاری قدرتمند برای مدل‌سازی روابط میان بازیگران معرفی شدند. در این چارچوب، هر فرد به عنوان یک گره^{۲۰} و تعاملات میان افراد به عنوان یال^{۲۱} در یک گراف در نظر گرفته می‌شوند. با استفاده از شبکه‌های کانولوشنی گرافی^{۲۲}، این مدل‌ها قادرند اطلاعات را در میان گره‌ها منتشر کرده و الگوهای تعاملی پیچیده را استخراج کنند. این رویکرد به ویژه در محیط‌های ورزشی، که تعاملات میان بازیکنان نقش کلیدی در تعیین فعالیت گروهی دارند، بسیار مؤثر است [۵]. علاوه بر این، ترکیب این مدل‌ها با مکانیزم‌های توجه امکان وزن‌دهی پویا به بازیگران مختلف را فراهم می‌کند، به گونه‌ای که مدل بتواند بر افراد یا تعاملات مهم‌تر تمرکز کند. اگرچه این رویکردها دقت مدل‌ها را به طور قابل توجهی افزایش داده‌اند، اما ساخت گراف و محاسبه تعاملات میان تمامی بازیگران منجر به افزایش پیچیدگی محاسباتی می‌شود، که این موضوع به ویژه در سناریوهای بلادرنگ چالش برانگیز است.

۳.۴.۲ مدل‌های مبتنی بر ترنسفورمر^{۲۳}

در سال‌های اخیر، معماری‌های مبتنی بر ترنسفورمر^{۲۳} به عنوان یکی از پیشرفته‌ترین رویکردها در حوزه تشخیص فعالیت گروهی مطرح شده‌اند. این مدل‌ها با تکیه بر مکانیزم خودتوجهی^{۲۴}، قادرند وابستگی‌های بلندبرد را در داده‌ها مدل‌سازی کرده و روابط میان تمامی بازیگران را به صورت همزمان در نظر بگیرند.

یکی از مزیت‌های کلیدی این معماری‌ها، توانایی آن‌ها در یکپارچه‌سازی اطلاعات در سطح کل صحنه است. برخلاف مدل‌های گرافی که نیازمند تعریف صریح ساختار تعاملات هستند،

¹⁹Interaction-Aware and Relational Models

²⁰Nodes

²¹Edges

²²Graph Convolutional Networks (GCNs)

²³Transformers

²⁴Self-Attention Mechanisms

ترنسفورمرها این روابط را به صورت ضمنی و داده محور یاد می گیرند. این ویژگی باعث می شود که این مدل ها در مواجهه با سناریوهای پیچیده و پویا عملکرد بهتری داشته باشند [۱۲]. با این حال، این مزایا با هزینه هایی نیز همراه هستند. نیاز به داده های حجیم برای آموزش مؤثر و مصرف بالای منابع محاسباتی از جمله چالش های اصلی این رویکرد محسوب می شوند، که کاربرد آن ها را در برخی سناریوهای عملی محدود می کند.

۴.۴.۲ روش های مبتنی بر ژست^{۲۵}

در کنار رویکردهای مبتنی بر تصویر، استفاده از داده های ساختاری مانند اسکلت بدن نیز به عنوان یک مسیر پژوهشی مهم مطرح شده است. در این روش ها، به جای استفاده از تصاویر RGB، از داده های اسکلت بدن^{۲۶} برای نمایش وضعیت و حرکت افراد استفاده می شود. این بازنمایی انتزاعی امکان تمرکز بر ساختار حرکتی بدن را فراهم کرده و تأثیر عوامل مزاحم مانند تغییرات نور یا پس زمینه را کاهش می دهد.

مدل های مبتنی بر ژست با تحلیل توالی نقاط کلیدی بدن، قادرند روابط زمانی و فضایی میان افراد را به طور مؤثری استخراج کنند. این ویژگی باعث شده است که این رویکردها در کاربردهای ورزشی، که اطلاعات حرکتی نقش مهمی دارند، مورد توجه قرار گیرند [۱۳]. با این وجود، حذف اطلاعات بصری زمینه مانند موقعیت توپ یا شرایط محیطی و همچنین وابستگی شدید به دقت الگوریتم های تخمین ژست، از جمله محدودیت های این روش ها محسوب می شوند. در مجموع، پیشرفت های حاصل در این بخش نشان دهنده حرکت تدریجی از مدل های ساده تر به سمت رویکردهای پیچیده تر و جامع تر است، که هر یک تلاش می کنند جنبه ای از مسئله تشخیص فعالیت گروهی را با دقت بیشتری مدل سازی کنند.

۵.۲ کاربردها در تحلیل ویدیوهای ورزشی

کاربردهای تشخیص فعالیت گروهی در حوزه تحلیل ویدیوهای ورزشی بسیار گسترده و متنوع است. در این حوزه، هدف اصلی استخراج اطلاعات معنادار از رفتارهای تیمی و ارائه بینش هایی برای بهبود عملکرد است [۱۴، ۱۵]. برای مثال، تشخیص الگوهای بازی^{۲۷} امکان شناسایی استراتژی های حمله و دفاع را فراهم می کند، در حالی که تحلیل آرایش تیمی^{۲۸} به درک ساختار فضایی تیم ها کمک می کند. علاوه بر این، استخراج بینش های تاکتیکی^{۲۹} می تواند الگوهای پنهان در رفتارهای هماهنگ تیمی را آشکار سازد.

²⁵Pose-Based Approaches

²⁶Pose / Skeleton Data

²⁷Play Recognition

²⁸Formation Analysis

²⁹Tactical Insights

با این حال، محیط‌های ورزشی چالش‌های خاص خود را دارند. تراکم بالای بازیکنان، انسدادهای مکرر، تغییرات سریع دوربین و وابستگی شدید میان کنش‌های بازیکنان از جمله عواملی هستند که تحلیل این داده‌ها را دشوار می‌سازند. برای غلبه بر این چالش‌ها، سیستم‌های مدرن معمولاً از ترکیب منابع مختلفی مانند داده‌های ردیابی بازیکنان^{۳۰}، تخمین ژست^{۳۱} و دانش دامنه‌ای^{۳۲} استفاده می‌کنند تا درک جامع‌تری از صحنه به دست آورند.

۶.۲ مجموعه داده‌ها و بنچمارک‌ها

پیشرفت در حوزه تشخیص فعالیت گروهی تا حد زیادی وابسته به در دسترس بودن مجموعه داده‌های استاندارد و بنچمارک‌ها بوده است [۱، ۳]. مجموعه داده فعالیت جمعی^{۳۳} یکی از اولین منابع در این حوزه است که بر فعالیت‌های گروهی در صحنه‌های عمومی تمرکز دارد و به عنوان یک معیار پایه برای ارزیابی مدل‌ها مورد استفاده قرار گرفته است. در مقابل، مجموعه داده والیبال^{۳۴} به طور خاص برای سناریوهای ورزشی طراحی شده و شامل برچسب‌گذاری دقیق در سطوح فردی و گروهی است، که آن را به یکی از منابع مهم برای تحلیل رفتارهای تیمی تبدیل کرده است.

در ادامه توسعه این حوزه، مجموعه داده‌های تخصصی‌تری نیز معرفی شدند که تمرکز بیشتری بر تحلیل ویدیوهای ورزشی دارند. به عنوان مثال، مجموعه داده ساکرن^{۳۵} به طور گسترده در تحلیل مسابقات فوتبال مورد استفاده قرار می‌گیرد و شامل ویدیوهای کامل بازی، برچسب‌گذاری رویدادها، و اطلاعات زمانی دقیق است [۲۰]. این مجموعه داده امکان بررسی فعالیت‌های گروهی در مقیاس واقعی و در شرایط پیچیده مسابقات حرفه‌ای را فراهم می‌کند و به ویژه برای مطالعه تعاملات تیمی و تحلیل تاکتیکی بسیار ارزشمند است.

علاوه بر این، مجموعه داده‌های ردیابی ورزشی^{۳۶}، به ویژه در ورزش‌هایی مانند بسکتبال، اطلاعات دقیقی از مسیر حرکت بازیکنان و موقعیت توپ ارائه می‌دهند که برای تحلیل پویایی تیمی بسیار مفید هستند. این نوع داده‌ها امکان مدل‌سازی دقیق‌تری از تعاملات میان بازیکنان را فراهم کرده و در بسیاری از روش‌های مدرن مورد استفاده قرار می‌گیرند.

همچنین، مجموعه داده‌ای جدید با عنوان مجموعه داده ویدیوهای کنش‌های مسابقات فوتبال^{۳۷} نیز در سال‌های اخیر منتشر شده است که شامل ویدیوهای مسابقات فوتبال همراه با برچسب‌گذاری کنش‌ها و رویدادهای کلیدی بازی می‌باشد. این مجموعه داده با تمرکز بر تحلیل ریز-رویدادهای حرکتی بازیکنان و توپ، امکان بررسی دقیق‌تر تعاملات تاکتیکی و رفتارهای لحظه‌ای در جریان

³⁰Player Tracking Data

³¹Pose Estimation

³²Domain-specific Knowledge

³³Collective Activity Dataset

³⁴Volleyball Dataset

³⁵SoccerNet

³⁶Sports Tracking Datasets

³⁷Football Match Actions Video Dataset

بازی را فراهم می‌کند. داده‌های این مجموعه می‌توانند در توسعه مدل‌های تشخیص فعالیت گروهی در سناریوهای ورزشی واقعی نقش مهمی ایفا کنند. منبع این مجموعه داده در وب سایت kaggle دسترس است.^{۳۸} با وجود این منابع، همچنان محدودیت‌هایی از نظر تنوع داده‌ها و پوشش سناریوهای مختلف وجود دارد که می‌تواند بر توان تعمیم مدل‌های تشخیص فعالیت گروهی تأثیرگذار باشد.

۷.۲ چالش‌ها و شکاف‌های پژوهشی

با وجود پیشرفت‌های چشمگیر، تشخیص فعالیت گروهی همچنان با چالش‌های متعددی مواجه است [۱۶، ۱۷]. یکی از مهم‌ترین این چالش‌ها، مسئله انسداد و پیچیدگی بصری است، که در آن بازیکنان یکدیگر را می‌پوشانند و استخراج ویژگی‌های دقیق را دشوار می‌سازند. علاوه بر این، محدودیت در تنوع مجموعه داده‌ها باعث می‌شود که مدل‌ها در مواجهه با سناریوهای جدید عملکرد مطلوبی نداشته باشند.

از سوی دیگر، مدل‌سازی دقیق تعاملات پیچیده میان بازیکنان، به‌ویژه در شرایطی که تفاوت میان فعالیت‌ها بسیار ظریف است، همچنان یک مسئله باز محسوب می‌شود. در نهایت، بسیاری از روش‌های پیشرفته نیازمند منابع محاسباتی قابل توجهی هستند، که این امر کاربرد آن‌ها را در سیستم‌های بلادرنگ^{۳۹} محدود می‌کند.

۸.۲ چشم‌اندازهای آینده

با توجه به چالش‌های موجود، پژوهش‌های آینده در این حوزه به سمت توسعه روش‌هایی حرکت می‌کنند که بتوانند محدودیت‌های فعلی را برطرف کنند [۱۸، ۱۹]. یکی از مهم‌ترین این مسیرها، یادگیری چندوجهی^{۴۰} است که با ترکیب منابع مختلف داده، درک جامع‌تری از صحنه فراهم می‌کند. همچنین، یادگیری خودنظارتی^{۴۱} با بهره‌گیری از داده‌های بدون برچسب، امکان استفاده از حجم عظیمی از ویدیوها را فراهم می‌سازد.

در کنار این موارد، توسعه مدل‌های سبک‌وزن^{۴۲} برای کاربردهای بلادرنگ و همچنین روش‌های مبتنی بر استدلال بلندمدت^{۴۳} برای تحلیل توالی‌های طولانی، از دیگر جهت‌گیری‌های مهم پژوهشی محسوب می‌شوند.

³⁸<https://www.kaggle.com/datasets/itarek898/football-match-actions-video-dataset>

³⁹Real-time Systems

⁴⁰Multimodal Learning

⁴¹Self-supervised Learning

⁴²Lightweight Models

⁴³Long-term Reasoning

۹.۲ جمع‌بندی

در این فصل، سیر تکامل روش‌های تشخیص فعالیت گروهی از رویکردهای سنتی تا روش‌های پیشرفته یادگیری عمیق مورد بررسی قرار گرفت. نتایج نشان می‌دهد که حرکت از مدل‌های مبتنی بر ویژگی‌های دست‌ساخته به سمت مدل‌های داده‌محور، نقش مهمی در بهبود عملکرد این سیستم‌ها داشته است [۸، ۱۰]. همچنین، معرفی مدل‌های تعاملی و ترنسفورمری امکان درک دقیق‌تر روابط میان بازیگران را فراهم کرده است [۳، ۵، ۱۲].

در حوزه تحلیل ویدیوهای ورزشی، این پیشرفت‌ها زمینه‌ساز استخراج بینش‌های دقیق‌تری از رفتارهای تیمی شده‌اند [۱۴]. با این حال، چالش‌هایی مانند انسداد، محدودیت داده‌ها و پیچیدگی محاسباتی همچنان پابرجا هستند و نیازمند پژوهش‌های بیشتر در این حوزه می‌باشند [۱۶، ۱۸]. این مسائل نشان می‌دهند که هنوز ظرفیت قابل توجهی برای پیشرفت در این حوزه وجود دارد و مسیرهای پژوهشی آینده نقش مهمی در توسعه کاربردهای عملی این فناوری ایفا خواهند کرد.


جدول ۱.۲: خلاصه‌ای از رویکردهای بررسی شده تشخیص فعالیت‌های گروهی

نام	ایده اصلی	مزایا	معایب	مراجع
روش‌های سنتی	استفاده از ویژگی‌های مکانی-زمانی دستی (مانند شار نوری) و مدل‌های احتمالی ساختارمند مانند HMM و CRF.	مدل‌های تفسیرپذیر؛ نیاز به داده‌های کمتر؛ مدل‌سازی صریح وابستگی‌ها.	قدرت بازنمایی محدود؛ عملکرد ضعیف در صحنه‌های پیچیده؛ وابستگی به مهندسی ویژگی.	[۸، ۹، ۱۰]
مدل‌های زمانی سلسله‌مراتبی (CNN-RNN)	ترکیب CNN برای استخراج ویژگی‌های مکانی با RNN برای مدل‌سازی زمانی در سطوح مختلف.	ثبت الگوهای مکانی و زمانی؛ مناسب برای ویدیو؛ بازتاب ساختار دنیای واقعی.	عدم مدل‌سازی صریح تعاملات بین افراد؛ عملکرد محدود در سناریوهای شلوغ.	[۳]
مدل‌های رابطه‌ای (GCN)	بازنمایی افراد به عنوان گره‌های گراف و تعاملات به عنوان یال‌ها با استفاده از GCN و مکانیسم توجه.	مدل‌سازی صریح تعاملات؛ عملکرد عالی در سناریوهای چندنفره و ورزشی.	پیچیدگی محاسباتی بالا؛ فرآیند ساخت گراف هزینه‌بر است؛ نامناسب برای کاربرد بلادرنگ.	[۵]
مدل‌های مبتنی بر ترنسفورمر	استفاده از «خودتوجه» برای مدل‌سازی همزمان وابستگی‌های سراسری بین تمام افراد و فریم‌ها.	ثبت وابستگی‌های طولانی‌مدت؛ مدل‌سازی ضمنی تعاملات؛ عملکرد قوی در سناریوهای پیچیده.	نیاز به مجموعه داده‌های بسیار بزرگ؛ هزینه محاسباتی و حافظه بالا.	[۱۲]
رویکردهای مبتنی بر ژست	استفاده از اسکلت بدن انسان یا نقاط کلیدی به جای تصاویر RGB برای مدل‌سازی حرکت.	مقاوم در برابر نویز پس‌زمینه و تغییرات نور؛ تمرکز بر دینامیک‌های حرکتی؛ بازنمایی کارآمد.	از دست دادن اطلاعات بصری زمینه‌ای (اشیاء)؛ وابستگی به دقت تخمین ژست.	[۱۳]

فصل ۳

روش‌شناسی

در این فصل، چارچوب کلی روش پیشنهادی برای دسته‌بندی کنش‌های گروهی ارائه می‌شود. شکل ۱.۳ نمایی کلی از خط لوله‌ی پردازش در این پژوهش را نشان می‌دهد.



شکل ۱.۳: نمای کلی خط لوله‌ی دسته‌بندی کنش‌های گروهی

^۱ Frame Extraction
^۲ Feature Sequence

همان‌گونه که در شکل ۱.۳ مشاهده می‌شود، چارچوب کلی این پژوهش به‌صورت یک خط لوله‌ی چندمرحله‌ای برای تحلیل ویدیوهای ورزشی طراحی شده است. در این چارچوب، ابتدا داده‌ی ویدیویی به واحدهای پایه‌ای قابل پردازش (فریم‌ها) تبدیل شده و سپس هر فریم به یک نمایش عددی فشرده در فضای ویژگی نگاشت می‌شود.


در ادامه، این نمایش‌های سطح پایین در قالب یک ساختار توالی‌مند یا ساختارمند تجمیع شده و به یک مدل یادگیری برای استخراج الگوهای زمانی و وابستگی‌های بین اجزای صحنه وارد می‌شوند. این مدل می‌تواند بسته به رویکرد مورد استفاده، شامل معماری‌های مبتنی بر شبکه‌های عصبی بازگشتی، مدل‌های مبتنی بر ترنسفورمر یا روش‌های مبتنی بر گراف باشد و به طبع خط لوله کلی شامل تغییرات جزئی خواهد شد.

در نهایت، خروجی این مرحله به یک لایه‌ی تصمیم‌گیری نگاشت شده و برچسب کنش گروهی یا رویداد مورد نظر پیش‌بینی می‌شود. این ساختار کلی به‌گونه‌ای طراحی شده است که امکان جایگزینی یا توسعه‌ی مؤلفه‌های مختلف آن، به‌ویژه در بخش مدل‌سازی، فراهم باشد.

۱.۳ توصیف مجموعه داده و چالش‌های مرتبط

یکی از مهم‌ترین مراحل در مسائل تحلیل ویدیو، به‌ویژه در حوزه‌ی تحلیل کنش‌های ورزشی، فرآیند ساخت و آماده‌سازی مجموعه داده است. کیفیت و نحوه‌ی تهیه‌ی داده‌ها تأثیر مستقیمی بر عملکرد مدل‌های یادگیری ماشین دارد.

به‌طور کلی، فرآیند ساخت یک مجموعه داده‌ی مناسب برای مسئله‌ی دسته‌بندی کنش‌های فوتبالی شامل چندین مرحله‌ی متوالی است که از جمع‌آوری داده‌های خام تا برچسب‌گذاری و آماده‌سازی نهایی را در بر می‌گیرد.



شکل ۲.۳: مراحل اصلی در ساخت مجموعه داده برای تحلیل کنش‌های گروهی

در مرحله‌ی نخست، داده‌های ویدیویی از منابع مختلف جمع‌آوری می‌شوند که ممکن است شامل پخش مسابقات، ویدیوهای آنلاین یا پایگاه‌های داده‌ی عمومی باشند. در ادامه، بخش‌های مرتبط از ویدیوها استخراج شده و به کلیپ‌های کوتاه‌تر تقسیم می‌شوند.

یکی از چالش‌برانگیزترین مراحل، فرآیند برچسب‌گذاری^۳ است که معمولاً به‌صورت دستی انجام می‌شود و نیازمند دانش دامنه‌ای در تحلیل مسابقات ورزشی است. در این مرحله، هر کلیپ به یک کلاس کنش مشخص اختصاص داده می‌شود.

پس از آن، مسئله‌ی عدم توازن کلاس‌ها^۴ مطرح می‌شود، زیرا برخی کنش‌ها مانند پاس‌دادن به‌طور طبیعی بیشتر از سایر رویدادها رخ می‌دهند. این موضوع می‌تواند منجر به سوگیری مدل شود. در نهایت، داده‌ها به مجموعه‌های آموزش، اعتبارسنجی و آزمایش تقسیم شده و مراحل پیش‌پردازش بر روی آن‌ها اعمال می‌شود.

در سال‌های اخیر، برخی پژوهش‌ها تلاش کرده‌اند تا مشکل کمبود داده در حوزه‌ی تشخیص کنش‌های گروهی را از طریق تولید داده‌های مصنوعی برطرف نمایند. به‌عنوان نمونه، چارچوب M3Act^۵ به‌عنوان یک رویکرد مبتنی بر تولید ویدیو، امکان ایجاد داده‌های مصنوعی برای آموزش مدل‌های تشخیص کنش گروهی را فراهم می‌کند [۲۱]. در این روش، با بهره‌گیری از مدل‌های

³Annotation

⁴Class Imbalance

⁵M3Act: Multiple Modalities for Group Activity Recognition via Video Generation

مولد^۶ پیشرفته، سناریوهای مختلف کنش‌های گروهی شبیه‌سازی شده و به‌عنوان داده‌ی آموزشی مورد استفاده قرار می‌گیرند.



شکل ۳.۳: نمونه‌هایی از داده‌های مصنوعی تولید شده توسط چارچوب M3Act^۷

با وجود مزایای این رویکرد، پیاده‌سازی چنین سیستم‌هایی مستلزم استفاده از مدل‌های مولد پیچیده و منابع محاسباتی بسیار بالا^۸ است که اجرای آن‌ها در مقیاس پروژه‌های کارشناسی عملاً امکان‌پذیر نیست. از این‌رو، در این پژوهش تمرکز بر استفاده از مجموعه داده‌های آماده و روش‌های استاندارد یادگیری قرار داده شده است. شایان ذکر است که در این پژوهش، به دلیل محدودیت‌های زمانی و منابع، از یک مجموعه داده‌ی آماده استفاده شده است و فرآیند کامل ساخت مجموعه داده به صورت عملی پیاده‌سازی نشده است؛ با این حال، درک این مراحل برای تحلیل نتایج و توسعه‌های آتی ضروری است.

^۶Generative Models

^۷<https://cjerry1243.github.io/M3Act/>

^۸High Computational Cost

۲.۳ مدل‌های مورد بررسی

۱.۲.۳ نوع یک: مدل‌های ترکیبی کانولوشنی-توالی محور

در این بخش، یک دسته از روش‌های مبتنی بر ترکیب استخراج ویژگی‌های بصری و مدل‌سازی توالی مورد بررسی قرار می‌گیرد. در این رویکرد، به جای استفاده مستقیم از فریم‌های خام ویدیویی، ابتدا هر فریم به یک نمایش عددی فشرده در فضای ویژگی نگاشت می‌شود و سپس این نمایش‌ها در قالب یک ساختار دنباله‌ای مورد پردازش قرار می‌گیرند. به‌طور مشخص، در این چارچوب هر ویدیو به صورت یک دنباله از بردارهای ویژگی در سطح فریم نمایش داده می‌شود که این بردارها توسط یک شبکه‌ی عصبی کانولوشنی از پیش آموزش دیده^۹ استخراج شده‌اند. در ادامه، این توالی ویژگی‌ها به یک مدل توالی محور^{۱۰} وارد می‌شود تا وابستگی‌های زمانی^{۱۱} میان فریم‌ها مدل‌سازی گردد. لازم به ذکر است که در این سطح از مدل‌سازی، انتخاب معماری توالی محور می‌تواند متنوع باشد و شامل شبکه‌های عصبی بازگشتی، مدل‌های مبتنی بر ترنسفورمر^{۱۲} یا سایر روش‌های پیشرفته باشد. با این حال، در این پژوهش به منظور ایجاد یک خط مبنا^{۱۳}، تمرکز بر روی مدل‌های بازگشتی قرار گرفته است.

مدل ۱: رمزگذار کانولوشنی + شبکه عصبی بازگشتی

در این مدل، توالی ویژگی‌های استخراج شده به یک شبکه‌ی عصبی بازگشتی^{۱۴} داده می‌شود. این معماری به عنوان ساده‌ترین مدل توالی محور، توانایی محدودی در مدل‌سازی وابستگی‌های بلندمدت دارد، اما به عنوان یک مبنای مقایسه مورد استفاده قرار می‌گیرد.

مدل ۲: رمزگذار کانولوشنی + شبکه LSTM

در این ساختار، از شبکه‌ی حافظه‌ی کوتاه-بلندمدت^{۱۵} برای مدل‌سازی توالی استفاده می‌شود. این مدل با بهره‌گیری از سازوکار دروازه‌ها^{۱۶}، قادر به حفظ اطلاعات در بازه‌های زمانی طولانی‌تر بوده و معمولاً عملکرد بهتری نسبت به RNN ساده ارائه می‌دهد.

^۹Pretrained Convolutional Neural Network

^{۱۰}Sequence Model

^{۱۱}Temporal Dependencies

^{۱۲}Transformer-based Models

^{۱۳}Baseline

^{۱۴}Recurrent Neural Network (RNN)

^{۱۵}Long Short-Term Memory (LSTM)

^{۱۶}Gates

مدل ۳: رمزگذار کانولوشنی + شبکه LSTM دوطرفه

در این مدل، از نسخه‌ی دوطرفه‌ی LSTM^{۱۷} استفاده می‌شود که توالی را به‌صورت هم‌زمان در دو جهت زمانی (رو به جلو و معکوس) پردازش می‌کند. این ویژگی امکان بهره‌گیری از اطلاعات زمینه‌ای کامل‌تر را فراهم می‌سازد، هرچند ممکن است در داده‌های محدود منجر به بیش‌برازش شود.

به‌طور کلی، خط لوله‌ی این دسته از مدل‌ها شامل سه مرحله‌ی اصلی زیر است:

۱. استخراج ویژگی در سطح فریم با استفاده از یک رمزگذار کانولوشنی ثابت^{۱۸}

۲. مدل‌سازی توالی با استفاده از یک مدل توالی‌محور (در این پژوهش: LSTM، RNN و BiLSTM)

۳. طبقه‌بندی کنش‌ها با استفاده از یک لایه‌ی پیش‌بینی کاملاً متصل^{۱۹}

در نهایت، سیستم یک دنباله از فریم‌ها را به‌عنوان ورودی دریافت کرده و یکی از سه کلاس کنش شامل Red Card، Scoring و Tackling را به‌عنوان خروجی تولید می‌کند.

۲.۲.۳ نوع دو: مدل مبتنی بر ترنسفورمر فضایی-زمانی

در این بخش، معماری TimeSformer [۲۲] به‌عنوان یکی از مدل‌های مبتنی بر ترنسفورمر برای مسئله تشخیص فعالیت گروهی در ویدیوهای ورزشی مورد بررسی قرار می‌گیرد. برخلاف مدل‌های مبتنی بر شبکه‌های کانولوشنی سه‌بعدی یا معماری‌های ترکیبی CNN+RNN که وابستگی زمانی را به‌صورت ترتیبی مدل‌سازی می‌کنند، مدل TimeSformer با تکیه بر سازوکار خودتوجه قادر است روابط فضایی و زمانی را به‌صورت هم‌زمان و سراسری استخراج کند. این ویژگی باعث می‌شود که مدل بتواند وابستگی‌های بلندمدت میان فریم‌ها و همچنین تعاملات پیچیده میان بازیکنان را با دقت بیشتری مدل‌سازی نماید.

در مسئله تحلیل ویدیوهای ورزشی، رخدادهایی مانند گل، تکل یا کارت قرمز تنها وابسته به یک فریم خاص نیستند، بلکه توالی حرکات بازیکنان، موقعیت توپ، تغییرات صحنه و تعاملات جمعی در طول زمان نقش مهمی در تشخیص رویداد دارند. به همین دلیل، استفاده از معماری‌های مبتنی بر ترنسفورمر و توجه فضایی-زمانی می‌تواند عملکرد بهتری نسبت به مدل‌های سنتی ارائه دهد.


مدل مورد استفاده در این پژوهش، نسخه پایه TimeSformer مبتنی بر معماری Vision Transformer (ViT) [۲۳] است که برای پردازش ویدیو توسعه داده شده است. این مدل،

¹⁷Bidirectional LSTM (BiLSTM)

¹⁸Frozen CNN Encoder

¹⁹Fully Connected Prediction Head

ویدیو را به عنوان دنباله‌ای از پچ^{۲۰} های تصویری در طول زمان در نظر گرفته و وابستگی‌های میان آنها را از طریق لایه‌های توجه چندسری استخراج می‌کند.



شکل ۴.۳: معماری ویژن ترنسفورمر [۲۳]

مراحل آماده‌سازی داده‌ها

در مرحله نخست، ویدیوهای مجموعه داده به تعداد مشخصی فریم نمونه برداری شدند. به منظور حفظ اطلاعات حرکتی و کاهش پیچیدگی محاسباتی، از هر ویدیو تعداد ثابتی فریم استخراج شد تا تمامی نمونه‌ها دارای طول یکسان باشند. سپس اندازه تمامی فریم‌ها به ابعاد ثابت تغییر داده شد تا ورودی استاندارد برای مدل فراهم گردد.

پس از استخراج فریم‌ها، عملیات نرمال‌سازی روی تصاویر اعمال شد. در این مرحله، مقادیر پیکسل‌ها بر اساس میانگین و انحراف معیار مجموعه داده ImageNet تنظیم شدند تا مدل بتواند از وزن‌های اولیه از پیش آموزش دیده استفاده کند. علاوه بر این، به منظور جلوگیری از بیش‌برازش و افزایش تنوع داده‌ها، برخی تبدیلات داده مانند تغییر اندازه و برش استاندارد روی فریم‌ها اعمال شد.

هر ویدیو در نهایت به یک بردار چهاربعدي شامل تعداد فریم‌ها، کانال‌های رنگی، ارتفاع و عرض تصویر تبدیل شد. این بردار به عنوان ورودی به مدل TimeSformer داده شد.

معماری مدل

معماری TimeSformer مبتنی بر تقسیم هر فریم به مجموعه‌ای از پچ‌های کوچک تصویری است. هر پچ پس از تخت‌سازی^{۲۱}، به یک بردار ویژگی تبدیل می‌شود. سپس تمامی بردارها به همراه

^{۲۰}Patch

^{۲۱}Flattening

کدگذاری مکانی و زمانی وارد بلوک‌های ترنسفورمر می‌شوند. در هر بلوک ترنسفورمر، عملیات توجه خودکار فضایی و زمانی انجام می‌شود. توجه فضایی، ارتباط میان نواحی مختلف یک فریم را استخراج می‌کند و توجه زمانی، وابستگی میان فریم‌های مختلف را مدل‌سازی می‌نماید. این ساختار باعث می‌شود مدل بتواند الگوهای حرکتی و تعاملات گروهی را در طول زمان یاد بگیرد. در انتهای معماری، خروجی توکن طبقه‌بندی به یک لایه کاملاً متصل داده می‌شود تا کلاس نهایی فعالیت پیش‌بینی گردد.

راهبرد آموزش مدل


به‌منظور بهره‌گیری از دانش اولیه مدل، از وزن‌های از پیش آموزش‌دیده روی مجموعه داده‌های بزرگ ویدیویی استفاده شد. سپس مدل روی مجموعه داده ورزشی این پژوهش بازنمایی^{۲۲} شد. برای آموزش مدل از تابع هزینه Cross Entropy Loss استفاده شد. همچنین بهینه‌سازی پارامترها با استفاده از الگوریتم AdamW انجام گرفت که برای مدل‌های مبتنی بر ترنسفورمر عملکرد پایدارتری ارائه می‌دهد. نرخ یادگیری اولیه به‌صورت کوچک تنظیم شد تا فرآیند ریزتنظیم مدل با ثبات بیشتری انجام شود.

به‌دلیل پیچیدگی بالای معماری ترنسفورمر و محدود بودن حجم داده‌ها، استفاده از وزن‌های اولیه از پیش آموزش‌دیده نقش مهمی در همگرایی مدل داشت. علاوه بر این، اندازه دسته‌های آموزشی متناسب با محدودیت حافظه پردازنده گرافیکی انتخاب شد.

فرآیند کلی اجرای مدل

فرآیند کلی اجرای مدل TimeSformer در این پژوهش مطابق شکل زیر انجام شده است:

^{۲۲}Fine-tuning



شکل ۵.۳: مراحل اصلی مدل مبتنی بر ترنسفورمر فضایی-زمانی

در این فرآیند، ابتدا فریم‌های کلیدی از هر ویدیو استخراج می‌شوند. سپس داده‌ها پس از پیش‌پردازش به پچ‌های تصویری تبدیل شده و وارد بلوک‌های ترنسفورمر می‌شوند. در ادامه، ویژگی‌های فضایی-زمانی استخراج شده و در نهایت کلاس فعالیت ورزشی توسط لایه طبقه‌بندی تعیین می‌شود.

مزایا و محدودیت‌های مدل

مهم‌ترین مزیت مدل TimeSformer توانایی آن در مدل‌سازی وابستگی‌های بلندمدت زمانی و روابط پیچیده فضایی میان بازیکنان است. برخلاف معماری‌های مبتنی بر کانولوشن که معمولاً دارای میدان دید محدود هستند، سازوکار توجه در ترنسفورمر امکان بررسی کل توالی ویدیو را فراهم می‌کند.

همچنین این مدل قابلیت استفاده از وزن‌های از پیش آموزش‌دیده را دارد که در شرایط محدود بودن داده‌ها بسیار مؤثر است. از سوی دیگر، پیچیدگی محاسباتی بالا و نیاز به حافظه زیاد از جمله محدودیت‌های اصلی این معماری محسوب می‌شود. به همین دلیل، انتخاب تعداد فریم‌ها و اندازه ورودی تأثیر مستقیمی بر هزینه محاسباتی مدل دارد.

۳.۳ صورت‌بندی مسئله

یک ویدیو به صورت یک دنباله از T فریم نمایش داده می‌شود:

$$V = [I_1, I_2, \dots, I_T]$$

در اینجا، هر فریم I_t با استفاده از یک استخراج‌کننده ویژگی از پیش آموزش‌دیده^{۲۳} به یک بردار ویژگی نگاشت می‌شود:

$$x_t = f_{enc}(I_t), \quad x_t \in \mathbb{R}^{512}$$

بنابراین، هر ویدیو به صورت یک دنباله از ویژگی‌ها نمایش داده می‌شود:

$$X = [x_1, x_2, \dots, x_T], \quad X \in \mathbb{R}^{T \times 512}$$

هدف این مسئله، یادگیری یک نگاشت^{۲۴} از فضای توالی ویژگی‌ها به فضای برجسب‌ها است:

$$f(X) \rightarrow y$$

که در آن $y \in \{1, 2, 3\}$ متناظر با کلاس‌های زیر است:

- کارت قرمز^{۲۵}
- گل زنی^{۲۶}
- تکل زدن (یا تقابل فیزیکی برای تصاحب توپ)^{۲۷}

این مسئله به صورت یک مسئله طبقه‌بندی چندکلاسه‌ی نظارت‌شده بر روی داده‌های توالی^{۲۸} فرموله می‌شود.

²³Pretrained Feature Extractor

²⁴Mapping

²⁵Red Card

²⁶Scoring

²⁷Tackling

²⁸Supervised Multi-class Sequence Classification

فصل ۴

ارزیابی و تحلیل نتایج

در این فصل، عملکرد مدل‌های پیشنهادی و آزمایش‌شده در این پژوهش مورد بررسی و ارزیابی قرار می‌گیرد. ابتدا با تحلیل آماری مجموعه داده‌ها، درک بهتری از توزیع داده‌ها و چالش‌های موجود حاصل می‌شود. سپس معیارهای ارزیابی مورد استفاده معرفی شده و اهمیت هر یک در سنجش عملکرد مدل‌ها تشریح می‌گردد. این معیارها مبنای مقایسه مدل‌ها در بخش‌های بعدی خواهند بود و به تفسیر دقیق‌تر نتایج کمک می‌کنند.

۱.۴ تحلیل آماری مجموعه داده


مجموعه داده‌ی مورد استفاده در این پژوهش از یک منبع عمومی در ^۱Kaggle استخراج شده و شامل ویدیوهای کوتاه از مسابقات فوتبال با برچسب‌های کنشی می‌باشد. این مجموعه داده به سه بخش آموزش^۲، اعتبارسنجی^۳ و ارزیابی^۴ تقسیم شده است.

^۱<https://www.kaggle.com/datasets/itarek898/football-match-actions-video-dataset>

^۲Training

^۳Validation

^۴Evaluation



شکل ۱.۴: نمودار میله‌ای^۵ توزیع کلاس‌های دیتاست کنش‌های فوتبالی

همان‌طور که شکل ۱.۴ نشان می‌دهد، مجموعه داده دارای عدم توازن کلاس‌ها است؛ به‌طوری که کلاس گل‌زنی دارای بیشترین تعداد نمونه بوده و به‌طور قابل توجهی از سایر کلاس‌ها غالب‌تر است. اما نکته خوب ماجرا اینجاست که توزیع نمونه‌ها در همه بخش‌های داده (آموزش، ارزیابی و آزمایش) تا حدود زیادی مشابه است. این نکته گرچه ساده بنظر می‌رسد، اما نقش بسزایی در عملکرد مدل دارد. باید توجه داشت که در یکسری از اوقات این فرض صادق نیست و باید راهکارهای مقتضی را بکار گرفت تا نقش عدم توازن کلاس‌ها را کمرنگ کرد. از جمله این روش‌ها میتوان به روش «زیرنمونه‌گیری منفی»^۶ اشاره کرد در رویکرد زیرنمونه‌گیری منفی، از میان کلاس‌هایی با تعداد نمونه‌ی بسیار بالا، بخشی از داده‌ها به‌صورت تصادفی حذف می‌گردند تا توزیع نمونه‌ها در تمامی طبقه‌ها به تعادل نزدیک‌تر شود. این امر علاوه بر کاهش هزینه‌های محاسباتی، از غلبه‌ی کلاس‌های پرجمعیت بر فرایند آموزش جلوگیری کرده و منجر به بهبود توانایی مدل در تشخیص دقیق‌تر کلاس‌های اقلیت و استخراج ویژگی‌های تمایزگذار در تمامی دسته‌ها می‌شود.

^۵Bar Chart

^۶Negative Subsampling



(آ) تصویر اول: فریمی از صحنه دریافت کارت قرمز



(ب) تصویر دوم: فریمی از صحنه به ثمر رسیدن گل



(ج) تصویر سوم: فریمی از صحنه‌ی یک درگیری فوتبالی

شکل ۲.۴: چند نمونه از دیتاست کنش‌های فوتبالی

در مجموع، تحلیل آماری مجموعه داده‌ها به درک بهتر ویژگی‌های داده، شناسایی چالش‌های بالقوه، و انتخاب مناسب‌تر روش‌های مدل‌سازی کمک می‌کند.

۲.۴ معیارهای ارزیابی

برای ارزیابی عملکرد مدل‌های طبقه‌بندی، استفاده از معیارهای مناسب ضروری است. در این پژوهش، از چهار معیار اصلی شامل دقت کلی، دقت به‌ازای هر کلاس، میانگین F_1 ماکرو و میانگین F_1 وزنی استفاده شده است. هر یک از این معیارها جنبه متفاوتی از عملکرد مدل را نشان می‌دهند و در کنار یکدیگر تصویر جامع‌تری ارائه می‌دهند.

۱.۲.۴ دقت کلی^۷

دقت کلی یکی از ساده‌ترین و متداول‌ترین معیارهای ارزیابی در مسائل طبقه‌بندی است. این معیار نسبت تعداد پیش‌بینی‌های صحیح به کل نمونه‌ها را اندازه‌گیری می‌کند. دقت کلی دید کلی از عملکرد مدل ارائه می‌دهد و به‌ویژه زمانی که داده‌ها متوازن باشند، معیار مناسبی محسوب می‌شود. با این حال، در شرایطی که توزیع کلاس‌ها نامتوازن باشد، دقت کلی می‌تواند گمراه‌کننده باشد. به‌عنوان مثال، اگر یک کلاس به‌طور قابل توجهی غالب باشد، مدلی که همواره آن کلاس را پیش‌بینی می‌کند ممکن است دقت بالایی داشته باشد، در حالی که عملکرد واقعی آن ضعیف است.

۲.۲.۴ دقت به‌ازای هر کلاس^۸

برای رفع محدودیت‌های دقت کلی، بررسی دقت به‌ازای هر کلاس اهمیت پیدا می‌کند. این معیار عملکرد مدل را به‌صورت جداگانه برای هر کلاس ارزیابی می‌کند و نشان می‌دهد که مدل تا چه حد قادر به تشخیص صحیح نمونه‌های هر کلاس است. این معیار به‌ویژه در مسائل نامتوازن اهمیت دارد، زیرا می‌تواند نشان دهد که آیا مدل نسبت به یک کلاس خاص سوگیری دارد یا خیر. تحلیل این معیار به شناسایی نقاط ضعف مدل کمک کرده و امکان بهبود هدفمند را فراهم می‌سازد.

۳.۲.۴ صحت^۹

معیار صحت که با نام ارزش پیش‌بینی مثبت^{۱۰} نیز شناخته می‌شود، به ارزیابی میزان دقت مدل در برچسب‌گذاری نمونه‌های مثبت می‌پردازد. به عبارت دیگر، این شاخص مشخص می‌کند که از میان تمامی نمونه‌هایی که توسط مدل به عنوان یک کنش خاص (مثلاً گل زدن) تشخیص داده شده‌اند، چه نسبتی واقعاً متعلق به آن طبقه بوده‌اند. بالا بودن میزان صحت به معنای کم بودن تعداد مثبت‌های

^۷Accuracy

^۸Per-Class Accuracy

^۹Precision

^{۱۰}Positive Predictive Value

کاذب^{۱۱} است. این معیار طبق رابطه ۱.۴ محاسبه می‌گردد:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (۱.۴)$$

که در آن TP تعداد مثبت‌های صحیح^{۱۲} و FP تعداد مثبت‌های کاذب است.

۴.۲.۴ بازخوانی^{۱۳}

معیار بازخوانی یا حساسیت^{۱۴}، بر توانایی مدل در بازیابی و شناسایی تمامی نمونه‌های مثبت موجود در مجموعه داده تمرکز دارد. در تشخیص کنش‌های فوتبالی، این معیار نشان می‌دهد که مدل تا چه حد موفق شده است تمامی رخدادهای واقعی (مثلاً تمام تکل‌های انجام شده در بازی) را شناسایی کند و چه میزان از آن‌ها را نادیده گرفته است. بالا بودن بازخوانی به معنای کم بودن تعداد منفی‌های کاذب^{۱۵} است. فرمول محاسباتی این معیار در رابطه ۲.۴ آمده است:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (۲.۴)$$

که در آن FN نشان‌دهنده تعداد نمونه‌های مثبتی است که مدل به اشتباه آن‌ها را منفی تشخیص داده است.

۵.۲.۴ میانگین F۱ ماکرو^{۱۶}

معیار F۱ ترکیبی از دو معیار صحت^{۱۷} و بازخوانی^{۱۸} است و تعادلی میان این دو برقرار می‌کند. در حالت ماکرو، مقدار F۱ برای هر کلاس به صورت جداگانه محاسبه شده و سپس میانگین آن‌ها گرفته می‌شود.

$$\text{Macro F1} = \frac{1}{N} \sum_{i=1}^N F1_i \quad (۳.۴)$$

که در آن N تعداد کل کلاس‌ها است.

^{۱۱}False Positives

^{۱۲}True Positive

^{۱۳}Recall

^{۱۴}Sensitivity

^{۱۵}False Negatives

^{۱۶}Macro F1-Score

^{۱۷}Precision

^{۱۸}Recall

ویژگی مهم میانگین ماکرو این است که به همه کلاس‌ها وزن یکسانی می‌دهد، صرف‌نظر از تعداد نمونه‌های آن‌ها. بنابراین، این معیار برای ارزیابی عملکرد مدل در کلاس‌های کم‌نمونه بسیار مناسب است و دیدی منصفانه از عملکرد کلی ارائه می‌دهد.

۶.۲.۴ میانگین F۱ وزنی^{۱۹}

در مقابل، میانگین F۱ وزنی با در نظر گرفتن تعداد نمونه‌های هر کلاس محاسبه می‌شود. به این صورت که مقدار F۱ هر کلاس متناسب با اندازه آن کلاس وزن‌دهی شده و سپس میانگین‌گیری انجام می‌شود.

$$\text{Weighted F1} = \frac{\sum_{i=1}^N w_i \times F1_i}{\sum_{i=1}^N w_i} \quad (۴.۴)$$

که در آن w_i تعداد نمونه‌های متعلق به کلاس i -ام است. این معیار بازتاب بهتری از عملکرد مدل در شرایط واقعی ارائه می‌دهد، زیرا تأثیر کلاس‌های پرنمونه را بیشتر در نظر می‌گیرد. در نتیجه، ترکیب این معیار با F۱ ماکرو امکان تحلیل دقیق‌تری از رفتار مدل در مواجهه با داده‌های نامتوازن فراهم می‌سازد.

¹⁹Weighted F1-Score

۳.۴ مقایسه عملکرد مدل‌ها

در این بخش، عملکرد مدل‌های مختلف مورد استفاده در این پژوهش به صورت کمی و کیفی مورد بررسی قرار می‌گیرد. برای هر مدل، نتایج حاصل از معیارهای ارزیابی شامل دقت کلی، میانگین F1 ماکرو و وزنی، و همچنین عملکرد به ازای هر کلاس گزارش می‌شود. علاوه بر این، با استفاده از جداول و تحلیل‌های تفصیلی، نقاط قوت و ضعف هر مدل در تشخیص کلاس‌های مختلف مورد بررسی قرار می‌گیرد. این تحلیل‌ها زمینه را برای مقایسه نهایی مدل‌ها و انتخاب بهترین رویکرد فراهم می‌کنند.

۱.۳.۴ مدل ۱: رمزگذار کانولوشنی + شبکه عصبی بازگشتی

در این مدل، از ترکیب شبکه‌های کانولوشنی برای استخراج ویژگی‌های مکانی و شبکه‌های عصبی بازگشتی برای مدل‌سازی وابستگی‌های زمانی استفاده شده است. این ساختار به‌ویژه برای تحلیل داده‌های ویدیویی مناسب است، زیرا قادر است هم اطلاعات فریم‌ها و هم توالی زمانی آن‌ها را در نظر بگیرد.

نتایج ارزیابی این مدل در جدول ۱.۴ ارائه شده است.


جدول ۱.۴: نتایج کلی مدل CNN+RNN

دقت	F1 ماکرو	F1 وزنی
0.8525	0.7670	0.8426

برای تحلیل دقیق‌تر، عملکرد مدل به تفکیک هر کلاس در جدول ۲.۴ نشان داده شده است.

جدول ۲.۴: عملکرد مدل CNN+RNN به ازای هر کلاس

کلاس	دقت	صحت	بازخوانی	F1 ماکرو	تعداد نمونه
کارت قرمز	0.6667	0.8571	0.6667	0.7500	9
گل	0.9756	0.8696	0.9756	0.9195	41
تکل	0.5455	0.7500	0.5455	0.6316	11



شکل ۳.۴: ماتریس درهم‌ریختگی^{۲۰} عملکرد مدل CNN+RNN روی داده‌های آزمایش

با توجه به نتایج به‌دست‌آمده، این مدل عملکرد مناسبی در تشخیص کلاس «گل» از خود نشان می‌دهد. مقدار بالای بازخوانی و $F1$ ماکرو برای این کلاس نشان می‌دهد که مدل قادر است اغلب نمونه‌های مربوط به گل را به‌درستی شناسایی کند. این موضوع احتمالاً به دلیل فراوانی بیشتر نمونه‌های این کلاس در مجموعه داده و الگوهای مشخص‌تر آن در داده‌های ویدیویی است. در مقابل، عملکرد مدل در کلاس‌های «کارت قرمز» و «تکل» ضعیف‌تر است. به‌ویژه در کلاس «تکل»، مقدار بازخوانی پایین (۰.۵۴۵۵) نشان می‌دهد که تعداد قابل توجهی از نمونه‌های این کلاس به‌درستی شناسایی نشده‌اند. این مسئله می‌تواند ناشی از شباهت بصری این رویداد با سایر کنش‌ها یا تعداد کمتر نمونه‌های آموزشی باشد. همچنین اختلاف قابل توجه بین $F1$ ماکرو (۰.۷۶۷۰) و $F1$ وزنی (۰.۸۴۲۶) نشان‌دهنده تأثیر عدم توازن داده‌ها است. از آنجا که کلاس «گل» سهم بیشتری از داده‌ها را دارد و عملکرد مدل در این کلاس بسیار خوب است، مقدار $F1$ وزنی افزایش یافته است، در حالی که $F1$ ماکرو تصویر واقع‌بینانه‌تری از عملکرد مدل در تمامی کلاس‌ها ارائه می‌دهد. به‌طور کلی، این مدل در یادگیری الگوهای غالب موفق عمل کرده، اما در تشخیص کلاس‌های کم‌نمونه و پیچیده‌تر با چالش مواجه است.

²⁰Confusion Matrix

۲.۳.۴ مدل ۲: رمزگذار کانولوشنی + LSTM

در این مدل، به جای استفاده از شبکه بازگشتی ساده، از معماری LSTM به منظور مدل سازی وابستگی های زمانی بلندمدت استفاده شده است. LSTM به دلیل داشتن ساختار حافظه دار، قادر است اطلاعات مهم را در طول توالی حفظ کرده و وابستگی های پیچیده تری را نسبت به شبکه های عصبی بازگشتی ساده یاد بگیرد. این ویژگی به ویژه در تحلیل ویدیوهای ورزشی که شامل توالی های زمانی معنادار هستند، اهمیت دارد. نتایج کلی این مدل در جدول ۳.۴ ارائه شده است.


جدول ۳.۴: نتایج کلی مدل CNN+LSTM

دقت	F۱ ماکرو	F۱ وزنی
0.9344	0.8989	0.9321

عملکرد مدل به تفکیک هر کلاس در جدول ۴.۴ نشان داده شده است.

جدول ۴.۴: عملکرد مدل CNN+LSTM به ازای هر کلاس

کلاس	دقت	صحت	بازخوانی	F۱ ماکرو	تعداد نمونه
کارت قرمز	0.7778	1.0000	0.7778	0.8750	9
گل	1.0000	0.9318	1.0000	0.9647	41
تکل	0.8182	0.9000	0.8182	0.8571	11



شکل ۴.۴: ماتریس درهم‌ریختگی عملکرد مدل CNN+LSTM روی داده‌های آزمایش

با توجه به نتایج به‌دست‌آمده، این مدل نسبت به مدل قبلی بهبود قابل توجهی در تمامی معیارها نشان می‌دهد. دقت کلی از مقدار 0.8525 به 0.9344 افزایش یافته و مقدار $F1$ ماکرو نیز به 0.8989 رسیده است که نشان‌دهنده بهبود عملکرد در تمامی کلاس‌ها، به‌ویژه کلاس‌های کم‌نمونه، است.

در کلاس «گل»، مدل عملکرد بسیار مطلوبی داشته و مقدار بازخوانی برابر با 1.0000 نشان می‌دهد که تمامی نمونه‌های این کلاس به‌درستی شناسایی شده‌اند. همچنین مقدار $F1$ -score بالا (0.9647) بیانگر تعادل مناسب بین دقت و بازخوانی در این کلاس است.

در کلاس «کارت قرمز»، اگرچه مقدار صحت برابر با 1.0000 است، اما بازخوانی برابر با 0.7778 نشان می‌دهد که هنوز برخی نمونه‌ها شناسایی نشده‌اند. با این حال، نسبت به مدل قبلی، بهبود قابل توجهی مشاهده می‌شود.

بیشترین پیشرفت مربوط به کلاس «تکل» است، جایی که بازخوانی از 0.5455 در مدل قبلی به 0.8182 افزایش یافته است. این نشان می‌دهد که استفاده از LSTM توانسته وابستگی‌های زمانی پیچیده‌تر را بهتر مدل‌سازی کرده و در نتیجه عملکرد مدل در تشخیص این کلاس بهبود یابد. همچنین نزدیکی مقادیر $F1$ ماکرو (0.8989) و $F1$ وزنی (0.9321) نشان می‌دهد که مدل عملکرد متعادلی در کلاس‌های مختلف دارد و تأثیر عدم توازن داده‌ها کاهش یافته است.

به‌طور کلی، جایگزینی RNN با LSTM منجر به بهبود چشمگیر در عملکرد مدل شده و

نشان می‌دهد که استفاده از معماری‌های پیشرفته‌تر برای مدل‌سازی توالی زمانی در مسئله تشخیص فعالیت‌های گروهی بسیار مؤثر است.

۳.۳.۴ مدل ۳: رمزگذار کانولوشنی + Bi-LSTM

در این مدل، به‌منظور بهره‌گیری هم‌زمان از اطلاعات گذشته و آینده در توالی‌های زمانی، از معماری Bi-LSTM استفاده شده است. برخلاف LSTM یک‌جهته، این مدل توالی را در هر دو جهت زمانی پردازش می‌کند و در نتیجه انتظار می‌رود بتواند وابستگی‌های پیچیده‌تری را در داده‌های ویدیویی استخراج کند. نتایج کلی این مدل در جدول ۵.۴ ارائه شده است.


جدول ۵.۴: نتایج کلی مدل CNN+Bi-LSTM

دقت	F۱ ماکرو	F۱ وزنی
0.8361	0.7523	0.8260

عملکرد مدل به تفکیک هر کلاس در جدول ۶.۴ نشان داده شده است.

جدول ۶.۴: عملکرد مدل CNN+Bi-LSTM به‌ازای هر کلاس

کلاس	دقت	صحت	بازخوانی	F۱ ماکرو	تعداد نمونه
کارت قرمز	0.7778	0.8750	0.7778	0.8235	9
گل	0.9512	0.8667	0.9512	0.9070	41
تکل	0.4545	0.6250	0.4545	0.5263	11



شکل ۵.۴: ماتریس درهم‌ریختگی عملکرد مدل CNN+Bi-LSTM روی داده‌های آزمایش

با توجه به نتایج، این مدل عملکرد ضعیف‌تری نسبت به مدل LSTM یک‌جهته از خود نشان داده است. دقت کلی برابر با 0.8361 بوده که نسبت به مقدار 0.9344 در مدل قبلی کاهش قابل توجهی دارد. همچنین مقدار F_1 ماکرو (0.7523) نشان‌دهنده افت عملکرد مدل در کلاس‌های مختلف، به‌ویژه کلاس‌های کم‌نمونه، است.

در کلاس «گل»، همچنان عملکرد مدل مناسب است و مقدار Recall برابر با 0.9512 نشان می‌دهد که بخش عمده‌ای از نمونه‌های این کلاس به‌درستی شناسایی شده‌اند. با این حال، مقدار F_1 -score (0.9070) نسبت به مدل LSTM کاهش یافته است.

در کلاس «کارت قرمز»، عملکرد مدل نسبتاً قابل قبول است و مقدار F_1 برابر با 0.8235 نشان می‌دهد که مدل توانسته تا حدی این کلاس را تشخیص دهد.

بیشترین افت عملکرد مربوط به کلاس «تکل» است، جایی که مقدار بازخوانی به 0.4545 کاهش یافته است. این موضوع نشان می‌دهد که مدل در تشخیص این کلاس با چالش جدی مواجه است و تعداد زیادی از نمونه‌های این کلاس را از دست داده است.

کاهش عملکرد این مدل را می‌توان به پیچیدگی بیشتر معماری Bi-LSTM و احتمال بیش‌برازش^{۲۱} نسبت داد. همچنین، در مجموعه داده‌های با حجم محدود، استفاده از مدل‌های پیچیده‌تر لزوماً به

²¹Overfit

بهبود عملکرد منجر نمی‌شود و حتی ممکن است باعث افت دقت شود. به‌طور کلی، اگرچه Bi-LSTM از نظر تئوری قادر به استخراج اطلاعات بیشتری از توالی است، اما در این مسئله خاص و با توجه به ویژگی‌های مجموعه داده، عملکرد آن نسبت به LSTM یک‌جته ضعیف‌تر بوده است.

۴.۳.۴ مدل ۴: مدل مبتنی بر ترنسفورمر فضایی-زمانی

در این بخش، عملکرد مدل مبتنی بر ترنسفورمر فضایی-زمانی TimeSformer مورد بررسی قرار می‌گیرد. این معماری با استفاده از سازوکار توجه قادر است وابستگی‌های فضایی و زمانی را به‌صورت همزمان مدل‌سازی کند و در نتیجه برای تحلیل ویدیوهای ورزشی و تشخیص فعالیت‌های گروهی گزینه‌ای مناسب محسوب می‌شود. برخلاف مدل‌های مبتنی بر شبکه‌های بازگشتی که اطلاعات زمانی را به‌صورت ترتیبی پردازش می‌کنند، در این معماری تمامی فریم‌ها به‌صورت همزمان مورد توجه قرار می‌گیرند. این ویژگی باعث می‌شود مدل بتواند تعاملات پیچیده میان بازیکنان و تغییرات صحنه را با دقت بیشتری استخراج کند. نتایج کلی این مدل در جدول ۷.۴ ارائه شده است.

جدول ۷.۴: نتایج کلی مدل TimeSformer


دقت	F۱ ماکرو	F۱ وزنی
1.0000	1.0000	1.0000

عملکرد مدل به تفکیک هر کلاس در جدول ۸.۴ نشان داده شده است.

جدول ۸.۴: عملکرد مدل TimeSformer به‌ازای هر کلاس

کلاس	دقت	صحت	بازخوانی	F۱ ماکرو	تعداد نمونه
کارت قرمز	1.0000	1.0000	1.0000	1.0000	9
گل	1.0000	1.0000	1.0000	1.0000	41
تکل	1.0000	1.0000	1.0000	1.0000	11

همان‌طور که مشاهده می‌شود، مدل TimeSformer در تمامی معیارهای ارزیابی به عملکرد کامل دست یافته است. دقت کلی، F۱ ماکرو و F۱ وزنی همگی برابر با 1.0000 هستند که نشان‌دهنده توانایی بسیار بالای مدل در تشخیص فعالیت‌های گروهی مختلف است. در کلاس «گل»، مدل تمامی نمونه‌ها را به‌درستی شناسایی کرده و هیچ خطایی مشاهده نشده است. این موضوع نشان می‌دهد که معماری ترنسفورمر فضایی-زمانی توانسته الگوهای حرکتی و تغییرات صحنه مرتبط با این رخداد را به‌صورت کامل یاد بگیرد.



شکل ۶.۴: ماتریس درهم‌ریختگی عملکرد مدل TimeSformer روی داده‌های آزمایش

همچنین در کلاس‌های «کارت قرمز» و «تکل» نیز عملکرد مدل کاملاً بدون خطا بوده است. این نتیجه اهمیت استفاده از سازوکار توجه فضایی-زمانی را نشان می‌دهد، زیرا این معماری قادر است ارتباط میان بازیکنان، تغییرات موقعیتی و وابستگی‌های زمانی طولانی‌مدت را بهتر از انواع شبکه‌های عصبی بازگشتی استخراج کند.

یکی از عوامل مهم در موفقیت این مدل، استفاده از وزن‌های از پیش آموزش دیده است. با توجه به محدود بودن اندازه مجموعه داده، آموزش کامل یک مدل ترنسفورمر از ابتدا می‌توانست منجر به بیش‌برازش شود؛ اما استفاده از دانش منتقل شده از مرحله پیش‌آموزش باعث افزایش پایداری آموزش و بهبود عملکرد نهایی شده است.

در مقایسه با مدل‌های قبلی، این معماری توانسته عملکرد بسیار بهتری ارائه دهد. در حالی که مدل‌های قبلی در برخی کلاس‌ها به‌ویژه «تکل» و «کارت قرمز» با افت عملکرد مواجه بودند، مدل TimeSformer تمامی کلاس‌ها را با دقت کامل تشخیص داده است.

همچنین برخلاف معماری‌های بازگشتی که اطلاعات زمانی را به‌صورت ترتیبی منتقل می‌کنند و ممکن است بخشی از اطلاعات در توالی‌های طولانی از بین برود، سازوکار توجه در ترنسفورمر امکان تحلیل همزمان تمامی فریم‌ها را فراهم می‌کند. این ویژگی در تحلیل فعالیت‌های گروهی که وابستگی زمانی و تعامل میان بازیکنان اهمیت بالایی دارد، نقش مهمی ایفا می‌کند.

با وجود عملکرد بسیار بالا، باید توجه داشت که دستیابی به دقت کامل ممکن است تا حدی تحت تأثیر محدود بودن اندازه مجموعه داده و تعداد کم نمونه‌های آزمون نیز باشد. بنابراین، برای ارزیابی دقیق‌تر قابلیت تعمیم مدل، استفاده از مجموعه داده‌های بزرگ‌تر و متنوع‌تر در پژوهش‌های آینده ضروری خواهد بود.

به‌طور کلی، مدل TimeSformer بهترین عملکرد را در میان تمامی مدل‌های بررسی‌شده ارائه داد و نشان داد که معماری‌های مبتنی بر ترنسفورمر فضایی-زمانی می‌توانند گزینه‌ای بسیار مؤثر برای مسئله تشخیص فعالیت گروهی در ویدیوهای ورزشی باشند.

فصل ۵

نتیجه‌گیری و چشم‌انداز آینده

۱.۵ نتیجه‌گیری

در فصل‌های قبل به تفصیل توضیح داده شد که تشخیص فعالیت گروهی یکی از مسائل مهم و چالش‌برانگیز در حوزه بینایی ماشین و تحلیل ویدیو به شمار می‌رود که هدف آن، درک رفتار جمعی افراد و تحلیل تعاملات میان آن‌ها در یک صحنه پویا است. این مسئله در کاربردهای مختلفی مانند نظارت هوشمند، تحلیل رفتار اجتماعی، سامانه‌های امنیتی و به‌ویژه تحلیل مسابقات ورزشی اهمیت فراوانی دارد. در سناریوهای ورزشی، تشخیص صحیح فعالیت‌های گروهی می‌تواند در تحلیل تاکتیکی تیم‌ها، بررسی عملکرد بازیکنان، تولید خلاصه مسابقات و حتی کمک به تصمیم‌گیری مربیان مورد استفاده قرار گیرد.

با وجود پیشرفت‌های قابل‌توجه در سال‌های اخیر، مسئله تشخیص فعالیت گروهی همچنان با چالش‌های متعددی همراه است. از جمله این چالش‌ها می‌توان به پیچیدگی تعاملات میان افراد، تغییرات سریع حرکتی، انسداد بازیکنان، تنوع زاویه‌های دوربین، تغییرات نور، شباهت میان برخی فعالیت‌ها و محدود بودن مجموعه داده‌های تخصصی ورزشی اشاره کرد. علاوه بر این، بسیاری از فعالیت‌های گروهی وابستگی زمانی و فضایی پیچیده‌ای دارند که مدل‌سازی آن‌ها نیازمند استفاده از معماری‌های پیشرفته یادگیری عمیق است.

در این پژوهش، مسئله تشخیص فعالیت گروهی در ویدیوهای ورزشی مورد بررسی قرار گرفت و تلاش شد تا عملکرد چندین معماری یادگیری عمیق در این حوزه ارزیابی شود. در ابتدا، مجموعه داده‌ای از ویدیوهای مسابقات فوتبال تهیه و سازمان‌دهی شد که شامل چند کلاس مختلف از فعالیت‌های گروهی بود. فرآیند آماده‌سازی داده‌ها برای ساخت یک مجموعه داده مناسب برای انجام این چنین پروژه‌هایی توضیح داده شد که با چالش‌ها و سختی‌های زیادی شامل استخراج ویدیوها، یکسان‌سازی ساختار داده‌ها، دسته‌بندی نمونه‌ها و آماده‌سازی آن‌ها برای آموزش مدل‌ها همراه بود. با توجه به محدود بودن توان محاسباتی و اندازه مجموعه داده، طراحی آزمایش‌ها به گونه‌ای انجام شد که بتوان حداکثر بهره را از داده‌های موجود استخراج کرد.

پس از آماده‌سازی داده‌ها، چندین مدل مبتنی بر یادگیری عمیق مورد آزمایش قرار گرفتند. در ابتدا، مدل‌های مبتنی بر ترکیب شبکه‌های عصبی کانولوشنی و شبکه‌های عصبی بازگشتی بررسی شدند. این مدل‌ها توانایی مناسبی در استخراج ویژگی‌های حرکتی و الگوهای زمانی موجود در توالی فریم‌ها داشتند، اما در مدل‌سازی وابستگی‌های بلندمدت میان فریم‌ها محدودیت‌هایی مشاهده شد. در ادامه، مدل TimeSformer به‌عنوان یک معماری مبتنی بر ترنسفورمر فضایی-زمانی مورد استفاده قرار گرفت. این مدل با استفاده از مکانیزم توجه قادر است روابط زمانی و فضایی میان فریم‌های ویدیویی را به‌صورت مؤثرتری مدل‌سازی کند. نتایج آزمایش‌ها نشان داد که مدل TimeSformer، عملکرد بسیارخوبی در مسئله تشخیص فعالیت گروهی ارائه می‌دهد و در استخراج وابستگی‌های پیچیده میان فریم‌ها موفق‌تر عمل می‌کند.

ارزیابی نتایج نشان داد که کیفیت و تنوع داده‌ها تأثیر مستقیمی بر عملکرد مدل‌ها دارد. همچنین برخی کلاس‌های فعالیت به دلیل شباهت زیاد در الگوهای حرکتی یا محدود بودن نمونه‌های آموزشی، همچنان با نرخ خطای بالاتری همراه بودند. علاوه بر این، محدودیت منابع محاسباتی و حجم بالای پردازش ویدیو از دیگر چالش‌های مهم در اجرای مدل‌های پیشرفته محسوب می‌شد. به‌طور کلی، نتایج این پژوهش نشان داد که استفاده از مدل‌های یادگیری عمیق، به‌ویژه معماری‌های مبتنی بر ترنسفورمر، می‌تواند رویکردی مؤثر برای تحلیل فعالیت‌های گروهی در ویدیوهای ورزشی باشد. همچنین این پژوهش بستری مناسب برای توسعه سامانه‌های هوشمند تحلیل مسابقات ورزشی و تحقیقات پیشرفته‌تر در حوزه تحلیل رفتار گروهی فراهم می‌کند.

جدول ۱.۵: تحلیل ساختاری و مقایسه‌ای معماری‌های تشخیص فعالیت گروهی

معماری	استخراج ویژگی فضایی	مدل‌سازی زمانی	پیچیدگی محاسباتی	مناسب برای داده محدود	مزایا	محدودیت‌ها
شبکه‌های کانولوشنی سه‌بعدی	بالا	مناسب برای وابستگی کوتاه‌مدت	بالا	نسبتاً ضعیف	استخراج هم‌زمان اطلاعات حرکتی و فضایی	مصرف حافظه و محاسبات زیاد
مدل‌های ترکیبی کانولوشنی-بازگشتی	بالا	مناسب	متوسط تا بالا	متوسط	تحلیل مناسب دنباله‌های زمانی	آموزش پیچیده و وابستگی به طول توالی
ترنسفورمر فضایی-زمانی مثل TimeSformer	بسیار بالا	بسیار قوی	بسیار بالا	متوسط تا ضعیف	استفاده مؤثر از مکانیزم توجه	زمان آموزش بالا و نیازمند GPU قدرتمند
شبکه‌های عصبی گرافنی	مبتنی بر روابط میان افراد	قوی در تحلیل تعاملات	متوسط تا بالا	متوسط	مدل‌سازی تعاملات اجتماعی و گروهی	وابستگی به داده‌های ساختاریافته
مدل‌های چندوجهی	بسیار بالا	قوی	بسیار بالا	ضعیف تا متوسط	استفاده هم‌زمان از اطلاعات مکمل	پیچیدگی طراحی و هماهنگ‌سازی داده‌ها

همان‌طور که در جدول ۱.۵ مشاهده می‌شود، هر خانواده معماری دارای نقاط قوت و محدودیت‌های خاص خود است. مدل‌های مبتنی بر ترنسفورمر و معماری‌های چندوجهی، اگرچه عملکرد قدرتمندی

در استخراج وابستگی‌های پیچیده فضایی-زمانی ارائه می‌دهند، اما نیازمند داده‌های گسترده و منابع پردازشی قابل‌توجه هستند. در مقابل، مدل‌های ساده‌تر مانند شبکه‌های کانولوشنی یا معماری‌های ترکیبی CNN+RNN در شرایط داده محدود و منابع سخت‌افزاری محدود عملکرد پایدارتری دارند. همچنین معماری‌های مبتنی بر گراف می‌توانند نقش مهمی در تحلیل تعاملات میان بازیکنان و درک ساختار گروهی فعالیت‌ها ایفا کنند که این موضوع در تحلیل مسابقات ورزشی اهمیت ویژه‌ای دارد.

۲.۵ کارهای آینده

با توجه به نتایج و محدودیت‌های موجود در این پژوهش، مسیرهای مختلفی برای توسعه و بهبود سامانه‌های تشخیص فعالیت گروهی در آینده وجود دارد.

یکی از مهم‌ترین موضوعات، استفاده از مجموعه داده‌های بزرگ‌تر و متنوع‌تر است. بسیاری از مدل‌های عمیق، به‌ویژه معماری‌های مبتنی بر ترنسفورمر، برای دستیابی به عملکرد مطلوب نیازمند داده‌های گسترده هستند. بنابراین، توسعه مجموعه داده‌های تخصصی در حوزه ورزش با تنوع بیشتر در نوع مسابقات، زاویه‌های دوربین، شرایط محیطی و فعالیت‌های گروهی می‌تواند موجب افزایش توانایی تعمیم مدل‌ها شود. همانطور که در بخش ۱.۳ اشاره شد، تولید و استفاده از داده‌های مصنوعی و ساخته شده توسط مدل‌های مولد نیز می‌تواند به عنوان راه نسبتاً کم‌هزینه‌تر مورد توجه واقع شود.

موضوع مهم دیگر، ترکیب چند وظیفه هوش مصنوعی^۱ در یک سامانه یکپارچه است. در بسیاری از پژوهش‌های جدید، تشخیص فعالیت فردی^۲ و تشخیص فعالیت گروهی به‌صورت هم‌زمان مورد بررسی قرار می‌گیرند تا مدل بتواند علاوه بر تحلیل رفتار جمعی، رفتار هر بازیکن را نیز به‌صورت جداگانه تحلیل کند. این رویکرد می‌تواند درک دقیق‌تری از تعاملات تیمی و ساختار تاکتیکی مسابقات فراهم کند.

همچنین استفاده از اطلاعات مکمل مانند موقعیت بازیکنان، داده‌های ردیابی^۳، تخمین اسکلت بدن (تخمین ژست)^۴ و روابط گرافی میان بازیکنان می‌تواند موجب بهبود عملکرد مدل‌ها شود. در سال‌های اخیر، استفاده از شبکه‌های عصبی گرافی^۵ برای مدل‌سازی تعاملات میان افراد در فعالیت‌های گروهی مورد توجه زیادی قرار گرفته است.

علاوه بر این، توسعه مدل‌های چندوجهی^۶ یکی از مسیرهای مهم آینده محسوب می‌شود. در چنین مدل‌هایی، علاوه بر اطلاعات بصری، می‌توان از داده‌های صوتی، متنی یا آماری مسابقات نیز استفاده کرد تا تحلیل دقیق‌تری از رویدادهای ورزشی حاصل شود.

یکی دیگر از مسیرهای مهم آینده، توسعه سامانه‌های بلادرنگ^۷ برای تحلیل زنده مسابقات است. در این حالت، علاوه بر دقت، سرعت پردازش نیز اهمیت بسیار زیادی خواهد داشت. بنابراین استفاده از مدل‌های سبک‌تر، روش‌های فشرده‌سازی مدل^۸ و تکنیک‌های بهینه‌سازی می‌تواند نقش مهمی در کاربرد عملی این سامانه‌ها داشته باشد.

¹Multi-Task Learning

²Human Activity Recognition

³Tracking Data

⁴Pose Estimation

⁵Graph Neural Networks

⁶Multimodal Models

⁷Real-Time Systems

⁸Model Compression

همچنین استفاده از روش‌های یادگیری خودنظارتی^۹ و یادگیری انتقالی^{۱۰} می‌تواند وابستگی مدل‌ها به داده‌های برچسب‌گذاری‌شده را کاهش دهد. این موضوع به‌ویژه در حوزه تحلیل ویدیوهای ورزشی اهمیت دارد؛ زیرا فرایند برچسب‌گذاری داده‌های ویدیویی بسیار زمان‌بر و پرهزینه است. در نهایت، یکی از موضوعات مهم آینده، توسعه مدل‌های توضیح‌پذیر^{۱۱} است تا مشخص شود مدل‌ها بر اساس چه ویژگی‌هایی تصمیم‌گیری می‌کنند. این موضوع می‌تواند اعتمادپذیری سامانه‌های هوشمند را افزایش داده و استفاده عملی از آن‌ها را در تحلیل مسابقات ورزشی تسهیل کند.

^۹Self-Supervised Learning

^{۱۰}Transfer Learning

^{۱۱}Explainable AI

واژه‌نامه فارسی به انگلیسی

فارسی	English
تشخیص فعالیت گروهی	Group Activity Recognition
بینایی کامپیوتر	Computer Vision
بینایی ماشین	Machine Vision
تعامل انسان-ماشین	Human-Machine Interaction
تشخیص کنش تک‌نفره	Single-person Action Recognition
روابط فضایی-زمانی	Spatio-temporal Relationships
توالی ویدیویی	Video Sequence
رفتار تیمی	Team Behavior
تحلیل ویدیوهای ورزشی	Sports Video Analysis
انسداد	Occlusion
یادگیری ماشین	Machine Learning
یادگیری عمیق	Deep Learning
ویژگی‌های دست‌ساخته	Handcrafted Features
تشخیص تعامل دونفره	Two-person Interaction Recognition
جریان نوری	Optical Flow
مسیرهای حرکتی	Motion Trajectories
توصیف‌گرهای ظاهری	Appearance Descriptors

فارسی	English
مدل‌های مارکوف پنهان	Hidden Markov Models
میدان‌های تصادفی شرطی	Conditional Random Fields
میدان‌های تصادفی سلسله‌مراتبی	Hierarchical Random Fields
شبکه‌های عصبی کانولوشنی	Convolutional Neural Networks
شبکه‌های عصبی بازگشتی	Recurrent Neural Networks
شبکه حافظه‌ی کوتاه-بلندمدت	Long Short-Term Memory
دروازه	Gate
شبکه‌های کانولوشنی گراف	Graph Convolutional Networks
مکانیزم توجه	Attention Mechanism
مکانیزم خودتوجه	Self-Attention Mechanism
ترنسفورمرها	Transformers
گره‌ها	Nodes
یال‌ها	Edges
روش‌های مبتنی بر ژست	Pose-Based Approaches
داده‌های اسکلت بدن	Pose / Skeleton Data
تشخیص الگوهای بازی	Play Recognition
تحلیل آرایش تیمی	Formation Analysis
بینش‌های تاکتیکی	Tactical Insights
داده‌های ردیابی بازیکنان	Player Tracking Data
تخمین ژست	Pose Estimation
دانش دامنه‌ای	Domain-specific Knowledge
مجموعه داده فعالیت جمعی	Collective Activity Dataset
مجموعه داده‌های ردیابی ورزشی	Sports Tracking Datasets
مسیرهای حرکت بازیکنان	Player Trajectories

فارسی	English
موقعیت توپ	Ball Position
یادگیری چندوجهی	Multimodal Learning
یادگیری خودنظارتی	Self-supervised Learning
مدل‌های سبک‌وزن	Lightweight Models
استدلال بلندمدت	Long-term Reasoning
مدل‌سازی توالی	Sequence Modeling
استخراج‌کننده‌ی ویژگی از پیش آموزش دیده	Pretrained Feature Extractor
تولید ویدیو	Video Generation
داده‌ی مصنوعی	Synthetic Data
هزینه‌ی محاسباتی بالا	High Computational Cost
مدل‌های مولد	Generative Models
نگاشت	Mapping
طبقه‌بندی چندکلاسه‌ی نظارت‌شده بر روی داده‌های توالی	Supervised Multi-class Sequence Classification
نمودار میله‌ای	Bar Chart
زیرنمونه‌گیری منفی	Negative Subsampling
دقت کلی	Accuracy
دقت به‌ازای هر کلاس	Per-Class Accuracy
میانگین F1 ماکرو	Macro F1-Score
میانگین F1 وزنی	Weighted F1-Score
بازخوانی	Recall
صحت	Precision
مثبت صحیح	True Positive (TP)
مثبت کاذب	False Positive (FP)

فارسی	English
منفی صحیح	True Negative (TN)
منفی کاذب	False Negative (FN)
حساسیت	Sensitivity
ماتریس درهم ریختگی	Confusion Matrix
بیش برآزش	Overfit
پچ	Patch
تخت سازی	Flattening
بازآموزی	Fine-tuning
یادگیری چندوظیفه‌ای	Multi-Task Learning
تشخیص فعالیت فردی	Human Activity Recognition
داده‌های ردیابی	Tracking Data
شبکه‌های عصبی گرافی	Graph Neural Networks
مدل‌های چندوجهی	Multimodal Models
سامانه‌های بلادرنگ	Real-Time Systems
فشرده سازی مدل	Model Compression
یادگیری خودنظارتی	Self-Supervised Learning
یادگیری انتقالی	Transfer Learning
هوش مصنوعی توضیح پذیر	Explainable AI

واژه‌نامه انگلیسی به فارسی

فارسی	English
تشخیص فعالیت گروهی	Group Activity Recognition
بینایی کامپیوتر	Computer Vision
بینایی ماشین	Machine Vision
تعامل انسان-ماشین	Human-Machine Interaction
تشخیص کنش تک‌نفره	Single-person Action Recognition
روابط فضایی-زمانی	Spatio-temporal Relationships
توالی ویدیویی	Video Sequence
رفتار تیمی	Team Behavior
تحلیل ویدیوهای ورزشی	Sports Video Analysis
انسداد	Occlusion
یادگیری ماشین	Machine Learning
یادگیری عمیق	Deep Learning
ویژگی‌های دست‌ساخته	Handcrafted Features
تشخیص تعامل دونفره	Two-person Interaction Recognition
جریان نوری	Optical Flow
مسیرهای حرکتی	Motion Trajectories
توصیف‌گرهای ظاهری	Appearance Descriptors

فارسی	English
مدل‌های مارکوف پنهان	Hidden Markov Models
میدان‌های تصادفی شرطی	Conditional Random Fields
میدان‌های تصادفی سلسله‌مراتبی	Hierarchical Random Fields
شبکه‌های عصبی کانولوشنی	Convolutional Neural Networks
شبکه‌های عصبی بازگشتی	Recurrent Neural Networks
شبکه حافظه‌ی کوتاه-بلندمدت	Long Short-Term Memory
دروازه	Gate
شبکه‌های کانولوشنی گراف	Graph Convolutional Networks
مکانیزم توجه	Attention Mechanism
مکانیزم خودتوجه	Self-Attention Mechanism
ترنسفورمرها	Transformers
گره‌ها	Nodes
یال‌ها	Edges
روش‌های مبتنی بر ژست	Pose-Based Approaches
داده‌های اسکلت بدن	Pose / Skeleton Data
تشخیص الگوهای بازی	Play Recognition
تحلیل آرایش تیمی	Formation Analysis
بینش‌های تاکتیکی	Tactical Insights
داده‌های ردیابی بازیکنان	Player Tracking Data
تخمین ژست	Pose Estimation
دانش دامنه‌ای	Domain-specific Knowledge
مجموعه داده فعالیت جمعی	Collective Activity Dataset
مجموعه داده‌های ردیابی ورزشی	Sports Tracking Datasets
مسیرهای حرکت بازیکنان	Player Trajectories

فارسی	English
موقعیت توپ	Ball Position
یادگیری چندوجهی	Multimodal Learning
یادگیری خودنظارتی	Self-supervised Learning
مدل‌های سبک‌وزن	Lightweight Models
استدلال بلندمدت	Long-term Reasoning
مدل‌سازی توالی	Sequence Modeling
استخراج‌کننده‌ی ویژگی از پیش آموزش دیده	Pretrained Feature Extractor
تولید ویدیو	Video Generation
داده‌ی مصنوعی	Synthetic Data
هزینه‌ی محاسباتی بالا	High Computational Cost
مدل‌های مولد	Generative Models
نگاشت	Mapping
طبقه‌بندی چندکلاسه‌ی نظارت‌شده بر روی داده‌های توالی	Supervised Multi-class Sequence Classification
نمودار میله‌ای	Bar Chart
زیرنمونه‌گیری منفی	Negative Subsampling
دقت کلی	Accuracy
دقت به‌ازای هر کلاس	Per-Class Accuracy
میانگین F1 ماکرو	Macro F1-Score
میانگین F1 وزنی	Weighted F1-Score
صحت	Precision
بازخوانی	Recall
مثبت صحیح	True Positive (TP)
مثبت کاذب	False Positive (FP)

فارسی	English
منفی صحیح	True Negative (TN)
منفی کاذب	False Negative (FN)
حساسیت	Sensitivity
ماتریس درهم ریختگی	Confusion Matrix
بیش برازش	Overfit
پچ	Patch
تخت سازی	Flattening
بازآموزی	Fine-tuning
یادگیری چندوظیفه ای	Multi-Task Learning
تشخیص فعالیت فردی	Human Activity Recognition
داده های ردیابی	Tracking Data
شبکه های عصبی گرافی	Graph Neural Networks
مدل های چندوجهی	Multimodal Models
سامانه های بلادرنگ	Real-Time Systems
فشرده سازی مدل	Model Compression
یادگیری خودنظارتی	Self-Supervised Learning
یادگیری انتقالی	Transfer Learning
هوش مصنوعی توضیح پذیر	Explainable AI

مراجع

- [1] W. Choi, K. Shahid, and S. Savarese, “What are they doing?: Collective activity classification using spatio-temporal relationship among people,” in *Proc. IEEE Int. Conf. Comput. Vis. Workshops (IC-CVW)*, 2009, pp. 1282–1289.
- [2] T. Lan, Y. Wang, W. Yang, S. N. Robinovitch, and G. Mori, “Discriminative latent models for recognizing contextual group activities,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 34, no. 8, pp. 1549–1562, 2012.
- [3] M. S. Ibrahim, S. Muralidharan, Z. Deng, A. Vahdat, and G. Mori, “A hierarchical deep temporal model for group activity recognition,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 1971–1980.
- [4] S. Herath, M. Harandi, and F. Porikli, “Going deeper into action recognition: A survey,” *Image Vis. Comput.*, vol. 60, pp. 4–21, 2017.
- [5] J. Wu, Z. Wang, and H. Wang, “Learning actor relation graphs for group activity recognition,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2019, pp. 9964–9974.
- [6] I. Laptev, “On space-time interest points,” *Int. J. Comput. Vis.*, vol. 64, no. 2–3, pp. 107–123, 2005.
- [7] A. Patron-Perez, M. Marszalek, A. Zisserman, and I. Reid, “High five: Recognising human interactions in TV shows,” in *Proc. Brit. Mach. Vis. Conf. (BMVC)*, 2010, pp. 50.1–50.11.

- [8] I. Laptev, M. Marszalek, C. Schmid, and B. Rozenfeld, “Learning realistic human actions from movies,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2008, pp. 1–8.
- [9] S. Savarese, A. DelPozo, J. C. Niebles, and L. Fei-Fei, “Spatial-temporal correlations for unsupervised action classification,” in *Proc. IEEE Workshop Motion Video Comput. (WMVC)*, 2008, pp. 1–8.
- [10] P. K. Turaga, R. Chellappa, V. S. Subrahmanian, and O. Udrea, “Machine recognition of human activities: A survey,” *IEEE Trans. Circuits Syst. Video Technol.*, vol. 18, no. 11, pp. 1473–1488, 2008.
- [11] S. Ji, W. Xu, M. Yang, and K. Yu, “3D convolutional neural networks for human action recognition,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 35, no. 1, pp. 221–231, 2013.
- [12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017, pp. 5998–6008.
- [13] L. Zhou, X. Meng, Z. Liu, M. Wu, Z. Gao, and P. Wang, “Human pose-based estimation, tracking and action recognition with deep learning: A survey,” *arXiv preprint arXiv:2310.13039*, 2023.
- [14] M. D. Rodriguez, J. Ahmed, and M. Shah, “Action MACH: A spatio-temporal maximum average correlation height filter for action recognition,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2008, pp. 1–8.
- [15] M. E. Hussein, M. Torki, M. A. Gawayyed, and M. El-Saban, “Human action recognition using a temporal hierarchy of covariance descriptors on 3D joint locations,” in *Proc. Int. Joint Conf. Artif. Intell. (IJCAI)*, 2013, pp. 2466–2472.
- [16] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 779–788.

- [17] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2015.
- [18] C. Feichtenhofer, H. Fan, J. Malik, and K. He, “SlowFast networks for video recognition,” in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2019, pp. 6202–6211.
- [19] I. Misra and L. van der Maaten, “Self-supervised learning of pretext-invariant representations,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 6706–6716.
- [20] S. Giancola, M. Amine, T. Dghaily, and B. Ghanem, “SoccerNet: A scalable dataset for action spotting in soccer videos,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW)*, 2018, pp. 1711–1721.
- [21] C.-J. Chang, D. Li, D. Patel, P. Goel, H. Zhou, S. Moon, S. S. Sohn, S. Yoon, V. Pavlovic, and M. Kapadia, “M3Act: Learning from synthetic human group activities,” *arXiv preprint arXiv:2306.16772*, 2024.
- [22] G. Bertasius, H. Wang, and L. Torresani, “Is space-time attention all you need for video understanding?,” in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2021, pp. 813–824.
- [23] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2021.

Abstract

This thesis investigates the problem of Group Activity Recognition (GAR) in sports video analysis using deep learning-based approaches. Group Activity Recognition aims to identify collective activities and interactions among multiple individuals within a scene by analyzing temporal and spatial patterns in video sequences. The increasing availability of sports video data and the growing demand for intelligent video understanding systems have made GAR an important research area in computer vision, with applications in sports analytics, tactical analysis, automated event understanding, surveillance, and human-centered artificial intelligence systems.

The primary objective of this research is to evaluate and compare modern deep learning architectures for recognizing group activities in sports environments while considering the limitations of small-scale datasets and constrained computational resources. To achieve this goal, multiple deep learning models with different architectural paradigms were investigated and implemented. Initially, convolutional and recurrent neural network-based approaches were studied to capture spatial and temporal information from video frames. Subsequently, transformer-based architectures, particularly the TimeSformer model, were explored due to their ability to model long-range temporal dependencies through self-attention mechanisms.

Experiments were conducted on a sports activity video dataset consisting of categorized football match action clips. The implemented models were trained and evaluated using standard performance metrics to analyze their effectiveness in recognizing group activities under realistic sports scenarios. The study also examined the advantages and limitations of each architectural family, including computational complexity, feature extraction capability, temporal modeling performance, and suitability for limited datasets.

The experimental results demonstrate that transformer-based video understanding approaches can achieve competitive performance in sports group activity recognition tasks by effectively modeling temporal relationships across video frames. However, the findings also indicate that dataset size, data diversity, and computational limitations significantly influence model generalization and overall recognition accuracy. Furthermore, the research

highlights the importance of balancing model complexity and resource efficiency when designing GAR systems for practical applications.

Overall, this thesis provides a comprehensive investigation of deep learning approaches for sports video-based Group Activity Recognition and presents an analytical comparison between conventional sequential architectures and modern transformer-based methods. The outcomes of this work contribute to a better understanding of the challenges and opportunities in GAR research and provide a foundation for future studies on multimodal analysis, larger-scale sports datasets, and more efficient spatio-temporal learning frameworks.



College of Science
School of Mathematics, Statistics, and Computer Science

Group Activity Recognition for Sports Video Analysis

Omid Naeef Nejad

Supervisor: Dr. Ziaeeatabar

A thesis submitted in partial fulfillment of the requirements for
the degree of B.Sc. in Computer Science

June 2026